UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE TECNOLOGIA DA UFPA (ITEC)
FACULDADE DE ENGENHARIA DA COMPUTAÇÃO

ELIAN RAMON DE SARGES RODRIGUES

PREDIÇÃO DO CÂNCER CERVICAL UTILIZANDO MACHINE LEARNING E TOMADA DE DECISÃO MULTICRITÉRIO

BELÉM/PA
2025

ELIAN RAMON DE SARGES RODRIGUES

PREDIÇÃO DO CÂNCER CERVICAL UTILIZANDO MACHINE LEARNING E TOMADA DE DECISÃO MULTICRITÉRIO

Trabalho de Conclusão de Curso, apresentado como requisito parcial para a obtenção de grau de Bacharel em Engenharia da Computação, pela Universidade Federal do Pará.

Orientador: Prof. Dr. Marcos Cesar da Rocha Seruffo
Universidade Federal do Pará

Coorientador: Me. Saulo William da Silva Costa
Universidade Federal do Pará

BELÉM/PA
2025

ELIAN RAMON DE SARGES RODRIGUES

PREDIÇÃO DO CÂNCER CERVICAL UTILIZANDO MACHINE LEARNING E TOMADA DE DECISÃO MULTICRITÉRIO

Trabalho de Conclusão de Curso, apresentado como requisito parcial para a obtenção de grau de Bacharel em Engenharia da Computação, pela Universidade Federal do Pará.

DATA DE APROVAÇÃO: 04/09/2025

CONCEITO: EXCELENTE

Prof. Dr. Marcos Cesar da Rocha Seruffo
Orientador - FEM/ITEC/UFPA

Me. Saulo William da Silva Costa
Coorientador - FCT/ITEC/UFPA

Prof. Dr. Diego Lisboa Cardoso
Membro - FCT/ITEC/UFPA

Prof. Dr. Igor Wenner Silva Falcão
Membro - Externo - (Instituto Tecnológico Vale)

Prof. Dr. Sérgio Henrique Monte Santo Andrade
Membro - Externo - (Estácio)

BELÉM/PA
2025

Dedico aos meus pais e a toda a minha família.

AGRADECIMENTOS

Agradeço, primeiramente, a Deus por cada conquista em minha vida, aos meus familiares, que sempre me apoiaram em todos os momentos.

Agradeço a todos os professores do curso de Engenharia da Computação pelo conhecimento compartilhado em especial ao meu orientador Marcos Cesar da Rocha Seruffo e meu coorientador Saulo William da Silva Costa.

Agradeço também ao meu amigo Elizeu que sempre se fez presente nos trabalhos e nas horas descontraídas.

"A matemática é o alfabeto no qual Deus escreveu o universo."(Galileu Galilei)

RESUMO

O uso de técnicas de Machine Learning (ML) tem registrado crescimento exponencial em diversas áreas do conhecimento, destacando-se particularmente na medicina, onde essas ferramentas vêm demonstrando valor significativo para o diagnóstico precoce de doenças. Entre essas condições, o câncer do colo do útero merece atenção especial por figurar entre as neoplasias mais prevalentes na população feminina da região Norte do Brasil, representando um significativo desafio para a saúde pública local. Este estudo propõe uma abordagem metodológica que combina algoritmos de ML com métodos de Tomada de Decisão Multicritério (MCDM) para selecionar a técnica de aprendizado de máquina mais adequada para previsão do câncer cervical. A metodologia incluiu uma etapa de reamostragem com SMOTETomek para tratamento do desbalanceamento de classes e uma etapa de seleção de Features, por meio do método do Random Forest, que identificou as variáveis mais relevantes para a predição. Foram avaliados diversos algoritmos supervisionados, enquanto os métodos MCDM, incluindo o Analytic Hierarchy Process (AHP) e o Technique for Order of Preference by Similarity to Ideal Solution (TOPSIS), foram utilizados para atribuição de pesos aos critérios de desempenho e para ranquear e avaliar os modelos com base em múltiplos critérios de desempenho. Os resultados obtidos indicaram o Random Forest como o mais eficaz, seguido pelo Decision Tree, ambos demonstrando capacidade discriminativa excepcional na predição de casos de câncer cervical. O desempenho superior desses algoritmos, aliado à eficácia das técnicas de pré-processamento adotadas, reforça a relevância de abordagens metodológicas que combinam seleção, tratamento de dados minoritários e avaliação multicritério para a seleção de algoritmos em contextos médicos complexos.
Palavras-chave: Machine Learning. Câncer cervical. Variável-alvo. Seleção de Features. Random Forest.

ABSTRACT

The use of Machine Learning (ML) techniques has experienced exponential growth across various fields of knowledge, with particular prominence in medicine, where these tools have demonstrated significant value for the early diagnosis of diseases. Among these conditions, cervical cancer deserves special attention as it ranks among the most prevalent neoplasms in the female population of Northern Brazil, representing a significant challenge for local public health. This study proposes a methodological approach that combines ML algorithms with Multi-Criteria Decision-Making (MCDM) methods to select the most suitable machine learning technique for predicting cervical cancer. The methodology included a resampling step using SMOTETomek to address class imbalance and a feature selection step, conducted through the Random Forest method, which identified the most relevant variables for prediction. Several supervised algorithms were evaluated, while MCDM methods, including the Analytic Hierarchy Process (AHP) and the Technique for Order of Preference by Similarity to Ideal Solution (TOPSIS), were used to assign weights to performance criteria and to rank and evaluate the models based on multiple performance criteria. The results indicated Random Forest as the most effective algorithm, followed by Decision Tree, both demonstrating exceptional discriminative ability in predicting cervical cancer cases. The superior performance of these algorithms, combined with the effectiveness of the adopted preprocessing techniques, reinforces the relevance of methodological approaches that combine selection, minority data treatment, and multi-criteria evaluation for algorithm selection in complex medical contexts.
Keywords: Machine Learning. Cervical Cancer. Target Variable. Feature Selection. Random Forest.

LISTA DE FIGURAS

Figura 2.1 – Distribuição proporcional dos dez tipos de câncer mais incidentes estimados para 2023 por sexo, nível Brasil. 18
Figura 2.2 – Distribuição proporcional dos dez tipos de câncer mais incidentes estimados para 2023 por sexo, nível região Norte. 18
Figura 2.3 – Representação espacial das taxas ajustadas de incidência por 100 mil mulheres, estimadas para o ano de 2023, segundo Unidade da Federação (neoplasia maligna da mama feminina). 19
Figura 2.4 – Representação espacial das taxas ajustadas de incidência por 100 mil mulheres, estimadas para o ano de 2023, segundo Unidade da Federação (neoplasia maligna do colo do útero). 20
Figura 2.5 – Representação anatômica do colo do útero e suas estruturas. 21
Figura 2.6 – Tipos de aprendizado de máquina. 24
Figura 2.7 – Diagrama SVM para duas features. 24
Figura 2.8 – Inserção de novo ponto para K=3. 25
Figura 2.9 – Exemplo de DT para responder "is a person fit?". 26
Figura 2.10–Matriz de confusão binária. 27
Figura 2.11–Estrutura Hierárquica do Método AHP. 29
Figura 4.1 – Etapas do processo de dados. 39
Figura 4.2 – Distribuição das 4 variáveis-alvo. 41
Figura 4.3 – Distribuição das classes binárias de *Hinselmann* antes e após a reamostragem. 43
Figura 4.4 – Top 5 features em relação ao *Hinselmann*. 44
Figura 4.5 – Top 5 features em relação ao *Schiller*. 44
Figura 4.6 – Top 5 features em relação ao *Citology*. 45
Figura 4.7 – Top 5 features em relação ao *Biopsy*. 45
Figura 5.1 – Estrutura hierárquica com critérios e alternativas. 47

LISTA DE TABELAS

Tabela 2.1 – Escala de importância relativa. 30
Tabela 2.2 – Valores de RI para diferentes quantidades n. 31
Tabela 3.1 – Comparação de características de diferentes abordagens para detecção de câncer cervical e nossa proposta. 38
Tabela 4.1 – Tipos das features originais do dataset. 40
Tabela 4.2 – Valores nulos em cada uma das colunas. 42
Tabela 4.3 – Conjunto de dados atual para $Hinselmann$. 46
Tabela 5.1 – Distribuição de importâncias. 47
Tabela 5.2 – Pesos dos critérios. 48
Tabela 5.3 – Desempenho dos modelos para Hinselmann. 49
Tabela 5.4 – Ranqueamento dos modelos para Hinselmann. 49
Tabela 5.5 – Desempenho dos modelos Schiller. 50
Tabela 5.6 – Ranqueamento dos modelos para Schiller. 50
Tabela 5.7 – Desempenho dos modelos para Citology. 50
Tabela 5.8 – Ranqueamento dos Modelos para Citology. 51
Tabela 5.9 – Desempenho dos modelos para Biopsy. 51
Tabela 5.10–Ranqueamento dos Modelos para Biopsy. 51

LISTA DE SIGLAS

ML	Machine Learning
MCDM	Multiple-Criteria Decision-Making
AHP	Analytic Hierarchy Process
TOPSIS	Technique for Order of Preference by Similarity to Ideal Solution
INCA	Instituto Nacional de Câncer
CCU	Câncer Do Colo do Útero
HPV	Papilomavírus Humano
NIC	Neoplasia Intraepitelial Cervical
WHO	World Health Organization
PCCU	Prevenção do Câncer do Colo do Útero
IA	Inteligência Artificial
SVM	Suport Vector Machine
RF	Random Forest
KNN	k-Nearest Neighbors
LR	Logistic Regression
NB	Naive Bayes
DT	Decision Tree
TP	True Positive
TN	True Negative
FP	False Positive
FN	False Negative
CI	Consistency Index
CR	Consistency Ratio
RI	Random Index
TCC	Trabalho de Conclusão de Curso
SMOTE	Synthetic Minority Oversampling Technique
GA	Genetic Algorithm

GBM	Gradient Boosting Machine
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
XGBOOST	Extreme Gradient Boosting
CEP	Comité de Ética em Pesquisa

SUMÁRIO

1 INTRODUÇÃO . . . 14
1.1 Motivação . . . 15
1.2 Justificativas . . . 15
1.3 Objetivos . . . 16
1.3.1 Objetivo geral . . . 16
1.3.2 Objetivos específicos . . . 16
1.4 Organização do Trabalho . . . 16

2 REFERENCIAL TEÓRICO . . . 17
2.1 Histórico e Definição do Câncer . . . 17
2.2 Distribuição de Câncer No Brasil . . . 17
2.3 Câncer do Colo do Útero . . . 21
2.3.1 Definição . . . 21
2.3.2 Etiologia e Fatores de Risco . . . 21
2.3.3 Evolução da Doença e Sintomas . . . 22
2.3.4 Prevenção . . . 22
2.4 Machine Learning . . . 23
2.4.1 Tipos de Machine Learning . . . 23
2.4.2 Support Vector Machines (SVM) . . . 24
2.4.3 Logistic Regression (LR) . . . 25
2.4.4 K-Nearest Neighbors (KNN) . . . 25
2.4.5 Naive Bayes (NB) . . . 26
2.4.6 Decision Tree (DT)/Random Forest (RF) . . . 26
2.5 Métricas . . . 27
2.5.1 Confusion Matrix . . . 27
2.5.2 Accuracy . . . 28
2.5.3 Precision . . . 28
2.5.4 Recall . . . 28
2.5.5 F1-score . . . 28
2.6 Tomada de Decisão Multicritério . . . 28
2.6.1 AHP . . . 29
2.6.2 TOPSIS . . . 31

3 TRABALHOS RELACIONADOS . . . 33
3.1 Técnicas de Reamostragem . . . 33
3.1.1 Subamostragem . . . 33
3.1.2 Sobreamostragem . . . 33
3.1.3 Híbrido . . . 33
3.2 Técnicas de Seleção Features . . . 34
3.2.1 Filter . . . 34
3.2.2 Wrapper . . . 35
3.2.3 Embedded . . . 35
3.3 Classificação do Câncer Cervical . . . 36

4 MATERIAIS E MÉTODOS . . . 39

4.1 Conjunto de Dados **39**
4.1.1 Pré-processamento 40
4.1.1.1 Variáveis-Alvo 41
4.1.1.2 Valores Nulos 42
4.1.1.3 Normalização 42
4.1.1.4 Reamostragem Híbrida 43
4.1.2 Seleção de Features 43
4.2 Treinamento **46**
4.3 Aspectos Éticos **46**

5 RESULTADOS E DISCUSSÕES **47**
5.1 AHP **47**
5.1.1 Distribuição de Importâncias do AHP 47
5.1.2 Verificação de Consistência 48
5.2 TOPSIS **48**
5.2.1 Ranqueamento Hinselmann 49
5.2.2 Ranqueamento Schiller 50
5.2.3 Ranqueamento Citology 50
5.2.4 Ranqueamento Biopsy 51
5.3 Ranqueamento **51**
5.4 Comparação de Resultados **52**
5.5 Pontos de Atenção **54**

6 CONCLUSÃO **55**

REFERÊNCIAS **57**

1 INTRODUÇÃO

A vida humana é marcada por inúmeros desafios e dificuldades, sendo a saúde um dos aspectos mais imprevisíveis e preocupantes. Entre essas questões, as mulheres enfrentam adversidades específicas ao longo de suas vidas, incluindo doenças como o câncer do colo do útero, também chamado de câncer cervical, que se desenvolve na região do colo uterino e se caracteriza pelo crescimento anormal e descontrolado das células da região uterina, podendo se agravar e levar ao falecimento da paciente (BUZAID, A. Carlos and MALUF, F. Cotait, 2024). Paralelo a isso, muitas mulheres enfrentam barreiras geográficas, econômicas e culturais que dificultam a realização de exames como o Papanicolau, essencial para a detecção precoce da doença.

Quando detectado em estágios iniciais, o câncer cervical tem altas taxas de cura, com opções de tratamento como cirurgia conservadora e radioterapia. No entanto, em estágios avançados, quando a doença já compromete tecidos profundos ou se espalha para outras partes do corpo, como pulmões, fígado e vagina (National Cancer Institute, 2021), as opções de tratamento tornam-se mais complexas e invasivas, diminuindo significativamente as chances de sucesso. A taxa de mortalidade associada ao câncer de colo do útero é atribuída à falta de conscientização sobre a importância da detecção precoce (World Health Organization, 2019). No Brasil, a região Norte apresenta uma incidência particularmente alarmante, sendo a mais elevada do país (INCA, 2022).

Apesar de sua natureza silenciosa, os avanços tecnológicos têm desempenhado um papel crucial na detecção precoce dessa e de outras doenças, permitindo diagnósticos mais rápidos e completos, contribuindo para a redução dos casos fatais.

O setor de saúde gera regularmente enormes quantidades de dados, que podem ser analisados para extrair informações valiosas sobre pacientes diagnosticados com diversas doenças. Essas informações ajudam a identificar possíveis padrões ou tendências que podem ser utilizadas para prever a ocorrência de doenças futuras. Uma das estratégias eficazes para esse tipo de previsão é o uso de Machine Learning (ML), que permite processar e explorar grandes volumes de dados para obter previsões com certa porcentagem de confiança. O uso de ML no campo médico tem se mostrado promissor, pois, muitos estudos têm sido realizados com o objetivo de encontrar o modelo ideal para a previsão de doenças específicas. Por exemplo, Barreto (2018) usou redes neurais artificiais para prever a ocorrência de câncer cervical, testando várias topologias de rede para selecionar aquela com maior parâmetro de precision. Outro estudo de Debroy (2023) utilizou os algoritmos Random Forest e XGBoost para classificar a presença de vinte tipos diferentes de câncer, baseando-se na métrica de precision para determinar o melhor algoritmo para conjuntos de dados específicos.

A escolha do modelo ideal é essencial para garantir o sucesso nas previsões, além disso, as métricas de desempenho, como acuraccy, precision, recall, entre outras, ajudam na tomada de decisão, no entanto, é importante evitar o foco em uma ou duas métricas. Essa abordagem limitada, como destacada no estudo de Debroy (2023) ao verificar somente a precision, pode não revelar o algoritmo mais adequado para um contexto específico. Portanto, para uma decisão mais conceituada, usa-se os métodos de tomadas de decisão multicritérios (MCDM), pois esses métodos permitem a consideração de múltiplos critérios e múltiplas alternativas e são amplamente aplicáveis em diversas áreas do conhecimento, como na área da saúde. Por exemplo, os autores Akinsola et al. (2019) aplicaram Fuzzy AHP e Fuzzy TOPSIS para avaliar o desempenho de algoritmos de ML e de forma

semelhante, o estudo de Mudawi e Alazeb (2022) propôs um modelo para prever câncer cervical utilizando seis algoritmos como alternativas e três critérios para avaliação.

Essas abordagens utilizando técnicas de MCDM proporcionam uma análise mais holística e robusta, levando em consideração múltiplos fatores que afetam o desempenho dos algoritmos, resultando em uma escolha ajustada às necessidades específicas de cada pesquisador. Logo, o objetivo deste trabalho é utilizar um banco de dados de câncer cervical e selecionar o melhor algoritmo de machine learning, o qual deverá satisfazer alguns critérios específicos, por meio de dois métodos de Tomada de Decisão Multicritério. Esses métodos são o AHP, para definir a matriz par a par, a qual quantifica a importância relativa de cada critério e calcula os seus pesos, e o TOPSIS, o qual utiliza os pesos do método AHP como entrada para, posteriormente, ranquear as melhores alternativas.

Diante desse cenário, surge a questão central deste estudo: é possível integrar métodos de machine learning e técnicas de decisão multicritério de modo a selecionar o algoritmo mais adequado para a predição do câncer cervical, considerando múltiplas métricas de desempenho e as particularidades da doença?

1.1 Motivação

A motivação deste trabalho está ancorada na relevância social e científica de enfrentar o câncer cervical, uma das principais causas de mortalidade feminina em países em desenvolvimento e, particularmente, na região Norte do Brasil. Essa condição de saúde pública reflete não apenas falhas estruturais no acesso a exames de rastreamento e diagnóstico precoce, mas também desigualdades históricas que atingem de forma mais aguda populações em contextos socioeconômicos vulneráveis.

Para além do panorama epidemiológico, há também um elemento humano que confere urgência a esta investigação. Experiências pessoais do autor com casos de câncer cervical em seu círculo próximo reforçam a percepção de que a doença, quando não identificada precocemente, impõe não apenas sofrimento físico, mas também impactos emocionais e sociais profundos sobre as famílias. Esse contato direto com a realidade da enfermidade fortaleceu a convicção de que a ciência pode desempenhar um papel transformador na prevenção e no cuidado em saúde.

Além disso, as motivações deste trabalho também estão associadas ao desafio de aplicar, em um problema concreto de grande relevância social, os conhecimentos adquiridos ao longo da formação em Engenharia da Computação. O desenvolvimento de soluções que combinam análise de dados, aprendizado de máquina e métodos de apoio à decisão representa não apenas a consolidação das competências técnicas adquiridas no curso, mas também a oportunidade de transformar teoria em prática, unindo fundamentos de algoritmos e modelagem matemática a um propósito humanitário e científico.

Nesse sentido, o trabalho é motivado pela busca de soluções que unam inovação tecnológica e aplicabilidade prática, alinhando a inteligência artificial ao campo da saúde pública. Trata-se de um esforço para não apenas avançar o estado da arte em predição de doenças por meio de algoritmos de machine learning, mas também para aproximar tais avanços das necessidades concretas de populações que enfrentam barreiras estruturais no acesso ao diagnóstico.

1.2 Justificativas

A justificativa deste estudo repousa sobre a elevada incidência e mortalidade associadas ao câncer cervical, sobretudo na região Norte do Brasil, onde os índices superam

a média nacional. A precariedade na oferta de serviços especializados, somada a barreiras geográficas e socioeconômicas, compromete a efetividade de programas de rastreamento e retarda a detecção precoce, fator decisivo para a cura e sobrevida das pacientes. Tal cenário exige novas estratégias que incorporem ferramentas analíticas avançadas, capazes de apoiar decisões clínicas e políticas públicas de forma mais precisa e custo-efetiva.

Adicionalmente, a integração de algoritmos de machine learning com métodos de decisão multicritério apresenta-se como alternativa inovadora para enfrentar os desafios da heterogeneidade de dados clínicos e epidemiológicos. Diferentemente de abordagens tradicionais que priorizam apenas uma ou duas métricas de desempenho, essa combinação metodológica permite avaliar múltiplos critérios simultaneamente, oferecendo um processo mais robusto de seleção de modelos preditivos. Assim, busca-se evitar vieses técnicos e ampliar a confiabilidade dos resultados aplicados à saúde pública.

Por fim, este trabalho se justifica pela possibilidade de contribuir não apenas para a literatura científica sobre predição em oncologia, mas também para a prática em saúde coletiva. Ao propor um arcabouço metodológico que alia inovação tecnológica, custo-efetividade e adequação epidemiológica, o estudo visa fornecer subsídios para programas de rastreamento mais eficientes, capazes de reduzir desigualdades regionais e salvar vidas. Dessa forma, a pesquisa se insere no esforço mais amplo de promover equidade em saúde e uso inteligente de tecnologias emergentes.

1.3 Objetivos

1.3.1 Objetivo geral

Analisar e selecionar o modelo de machine learning mais adequado, dentre os investigados, aos critérios para prever a ocorrência de câncer cervical de um Dataset específico utilizando métodos de decisão.

1.3.2 Objetivos específicos

- Escolher um dataset para análise;
- Selecionar as variáveis mais importantes para treinamento;
- Aplicar o método AHP para os critérios analisados;
- Utilizar o método TOPSIS para ranquear as alternativas, tomando os pesos definidos pelo AHP como entrada;
- Analisar e comparar os resultados obtidos a partir dos métodos aplicados.

1.4 Organização do Trabalho

Este trabalho está estruturado em cinco capítulos, além desta introdução. O Capítulo 2 apresenta o referencial teórico, abordando a dimensão do problema do câncer cervical, os algoritmos e as métricas adotados. O Capítulo 3 revisa trabalhos relacionados, destacando as lacunas na literatura e as escolhas metodológicas que fundamentam esta pesquisa. O Capítulo 4 detalha os materiais e métodos, incluindo a descrição do dataset, técnicas de pré-processamento, seleção de Features e a integração entre AHP e TOPSIS. O Capítulo 5 discute os resultados obtidos, analisando-os e comparando-os com estudos anteriores. Por fim, o Capítulo 6 sintetiza as conclusões, limitações e propostas de trabalhos futuros.

2 REFERENCIAL TEÓRICO

Com o objetivo de situar o leitor no campo de conhecimento em que este trabalho se insere, serão discutidos os referenciais teóricos e metodológicos que orientam a pesquisa, destacando-se as contribuições mais relevantes para a temática investigada.

2.1 Histórico e Definição do Câncer

A história do câncer remonta a milhares de anos, embora seja difícil determinar com precisão quando a doença surgiu. Registros antigos sugerem que o câncer já afetava a humanidade desde os tempos mais remotos. Os primeiros relatos conhecidos foram encontrados em papiros egípcios datados de aproximadamente 3000 a.C., onde se descrevem tumores que se assemelham aos cânceres de mama e de útero. Naquele período, o conhecimento médico era rudimentar, e a doença era frequentemente interpretada como resultado de causas místicas ou maldições divinas (Binder et al., 2014).

Ao longo dos séculos, diversas teorias foram propostas para explicar o câncer. No século V a.C., o filósofo grego Hipócrates desenvolveu a teoria dos "humores", sugerindo que o desequilíbrio entre os quatro fluidos corporais (sangue, fleuma, bile amarela e bile negra) poderia levar ao surgimento de doenças, incluindo o câncer. Essa teoria introduziu uma compreensão inicial sobre a natureza das enfermidades, oferecendo uma abordagem que contemplava não apenas as causas, mas também o contexto e a evolução clínica das doenças. A obra de Hipócrates continua a ser relevante nos dias atuais, evidenciando sua influência duradoura na medicina (Galmarini, 2020).

Na contemporaneidade, a ciência moderna compreende o câncer como um grupo complexo de doenças que se desenvolvem quando células do corpo começam a crescer e se dividir de maneira descontrolada. Esse comportamento anômalo pode levar à invasão de tecidos e órgãos próximos, com potencial de disseminação para outras partes do corpo. Devido à sua diversidade, existem mais de cem tipos diferentes de câncer, cada um com características e padrões distintos de progressão (Instituto Vencer o Câncer, 2023).

2.2 Distribuição de Câncer No Brasil

No Brasil, o Ministério da Saúde, por meio do Instituto Nacional de Câncer (INCA), publicou a obra *Estimativa 2023: Incidência de Câncer no Brasil*, apresentando projeções detalhadas sobre a ocorrência de diferentes tipos de câncer no país. A publicação destaca as estimativas de incidência por regiões, estados e capitais para o ano de 2023, evidenciando desigualdades regionais e padrões que requerem atenção no planejamento de políticas públicas.

Figura 2.1 – Distribuição proporcional dos dez tipos de câncer mais incidentes estimados para 2023 por sexo, nível Brasil.

Localização Primária	Casos	%	Homens	Localização Primária	Casos	%	Mulheres
Próstata	71.730	30,0%		Mama feminina	73.610	30,1%	
Cólon e reto	21.970	9,2%		Cólon e reto	23.660	9,7%	
Traqueia, brônquio e pulmão	18.020	7,5%		Colo do útero	17.010	7,0%	
Estômago	13.340	5,6%		Traqueia, brônquio e pulmão	14.540	6,0%	
Cavidade oral	10.900	4,6%		Glândula tireoide	14.160	5,8%	
Esôfago	8.200	3,4%		Estômago	8.140	3,3%	
Bexiga	7.870	3,3%		Corpo do útero	7.840	3,2%	
Laringe	6.570	2,7%		Ovário	7.310	3,0%	
Linfoma não Hodgkin	6.420	2,7%		Pâncreas	5.690	2,3%	
Fígado	6.390	2,7%		Linfoma não Hodgkin	5.620	2,3%	

Fonte: Instituto Nacional de Câncer (2022).

A Figura 2.1 apresenta a estimativa de incidência de diversos tipos de câncer no país, diferenciando os dados por sexo. O gráfico destaca os maiores índices de câncer masculino e feminino, sendo, respectivamente, câncer de próstata e de câncer de mama, evidenciando a distribuição desses casos em âmbito nacional.

Figura 2.2 – Distribuição proporcional dos dez tipos de câncer mais incidentes estimados para 2023 por sexo, nível região Norte.

Localização Primária	Casos	%	Homens	Localização Primária	Casos	%	Mulheres
Próstata	2.760	26,5%		Mama feminina	2.410	22,4%	
Estômago	1.200	11,5%		Colo do útero	1.980	18,4%	
Traqueia, brônquio e pulmão	880	8,5%		Cólon e reto	740	6,9%	
Cólon e reto	690	6,6%		Traqueia, brônquio e pulmão	650	6,0%	
Cavidade oral	440	4,2%		Estômago	630	5,9%	
Leucemias	440	4,2%		Leucemias	350	3,3%	
Fígado	430	4,1%		Ovário	340	3,2%	
Sistema nervoso central	320	3,1%		Fígado	320	3,0%	
Esôfago	270	2,6%		Glândula tireoide	320	3,0%	
Laringe	260	2,5%		Sistema nervoso central	270	2,5%	

Fonte: Instituto Nacional de Câncer (2022).

Ao analisar os dados por região, Figura 2.2 observa-se, no Norte do Brasil, que as mulheres são mais frequentemente acometidas pelo câncer de mama e pelo câncer de colo do útero. Contudo, ao examinar a incidência de um único tipo de câncer em âmbito nacional, é possível identificar as regiões com maior concentração de casos. Diante disso, verificando, primeiramente, o câncer de mama, Figura 2.3, identifica-se quais são as regiões do Brasil onde a incidência é maior.

Figura 2.3 – Representação espacial das taxas ajustadas de incidência por 100 mil mulheres, estimadas para o ano de 2023, segundo Unidade da Federação (neoplasia maligna da mama feminina).

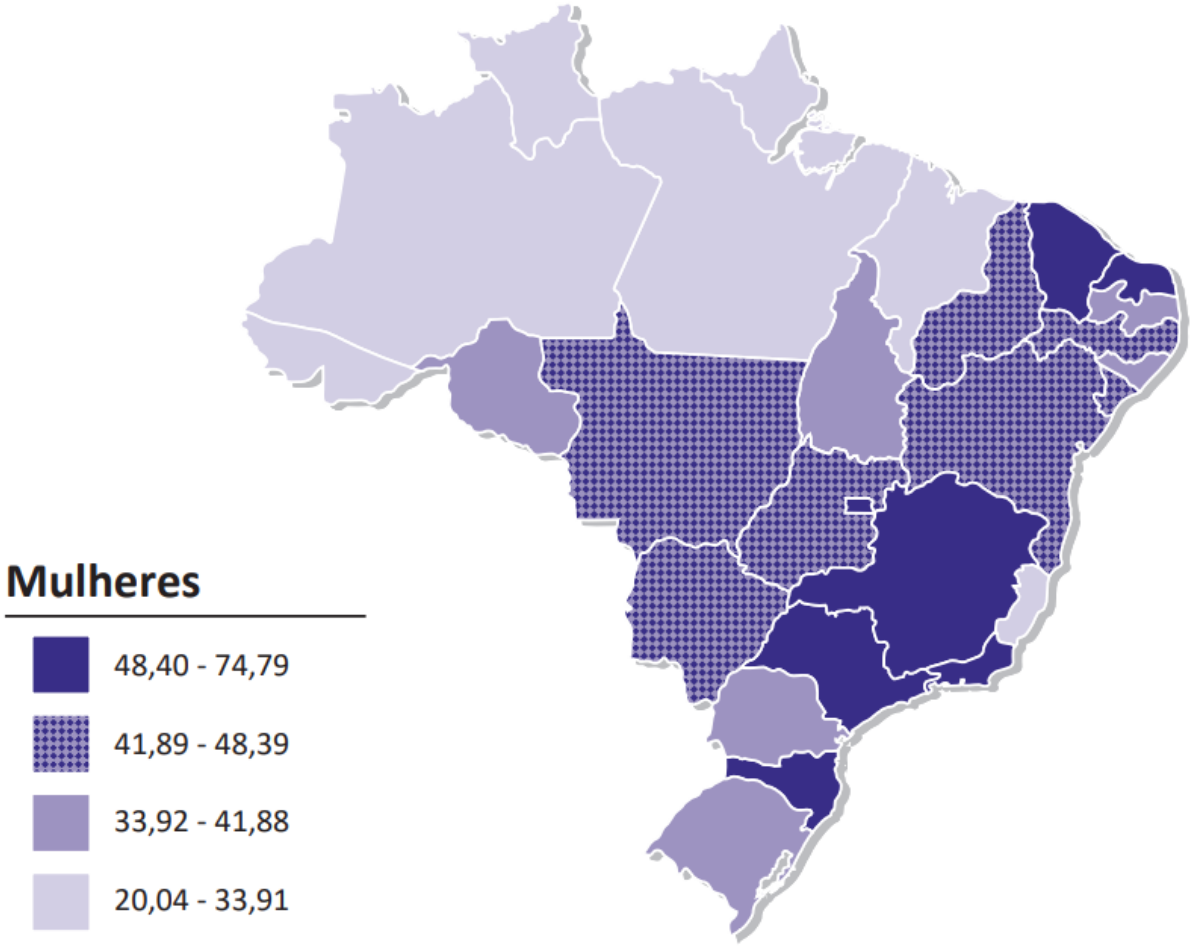

Fonte: Instituto Nacional de Câncer (2022).

A neoplasia maligna da mama feminina apresenta menor incidência na região Norte do Brasil, com os casos concentrados predominantemente no Sudeste. Dentre os Estados dessa região, três se destacam pelas taxas elevadas.

Ao analisar o mapa de incidência da neoplasia maligna do colo do útero, Figura 2.4, observa-se um padrão distinto e contrastante em relação à distribuição geográfica previamente identificada para o câncer de mama.

Figura 2.4 – Representação espacial das taxas ajustadas de incidência por 100 mil mulheres, estimadas para o ano de 2023, segundo Unidade da Federação (neoplasia maligna do colo do útero).

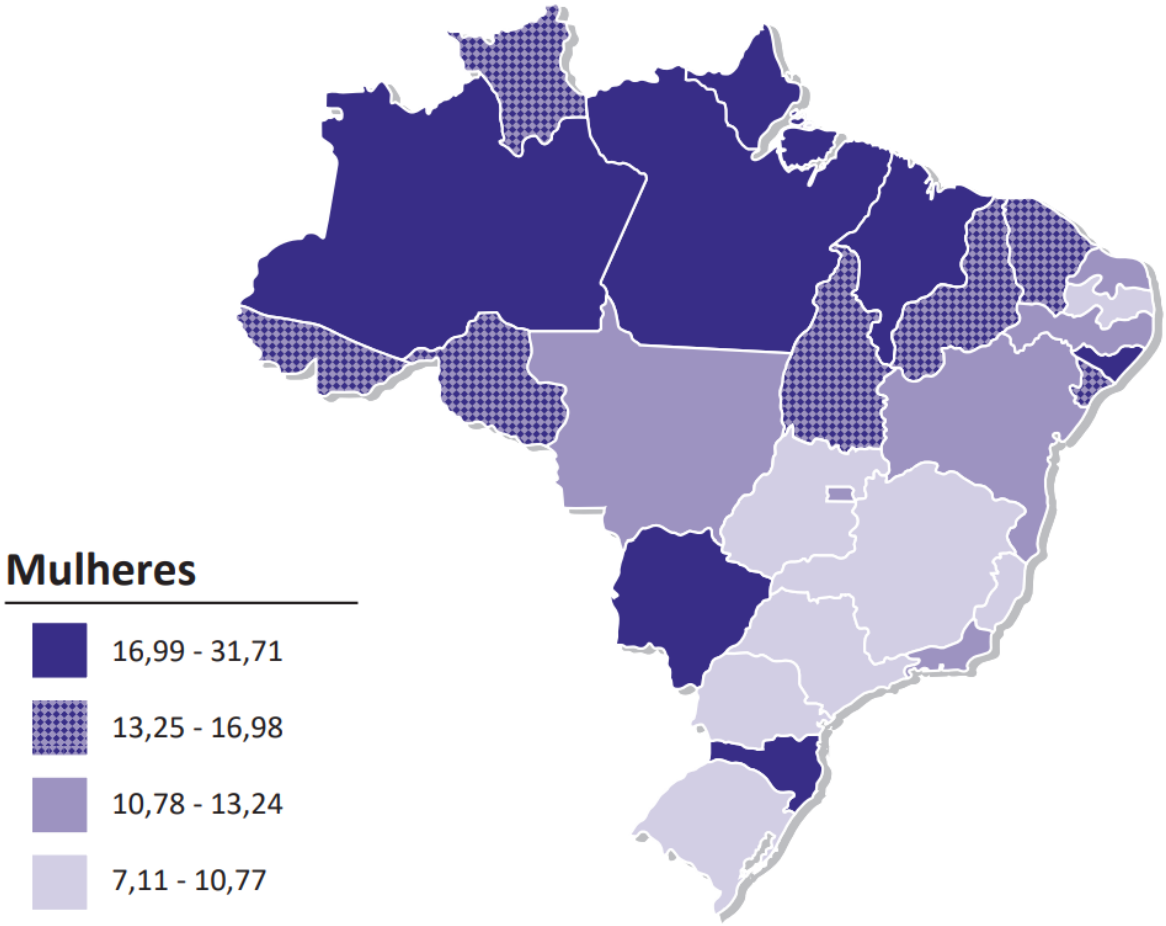

Fonte: Instituto Nacional de Câncer (2022).

O câncer cervical apresenta elevada concentração na região Norte, contrastando com a distribuição do câncer de mama que, embora seja o tipo mais prevalente entre mulheres em âmbito nacional, mostra menor incidência naquela região. Notavelmente, o câncer do colo do útero se apresenta como uma das neoplasias mais preocupantes para a população feminina nortista, com índices significativamente superiores aos observados em outras regiões do país.

A elevada incidência desse tipo de câncer é atribuída, dentre outros fatores: a vasta extensão territorial com comunidades isoladas e de difícil acesso na Amazônia, a qual dificulta o deslocamento da população até os centros urbanos para realização de exames preventivos; o limitado acesso à informação, com escassas campanhas educativas sobre a prevenção do HPV e a importância do rastreamento regular; a infraestrutura de saúde frágil, com pouca oferta de serviços especializados; e a demora no diagnóstico.

Esse panorama evidencia a interação entre determinantes socioeconômicos, fatores culturais e barreiras no acesso a programas de prevenção e diagnóstico precoce. Tal contexto reforça a necessidade de ampliar e aprofundar os estudos sobre a epidemiologia do câncer cervical na região Norte.

2.3 Câncer do Colo do Útero

Esta seção apresenta os aspectos epidemiológicos e clínicos fundamentais do câncer do colo do útero (CCU).

2.3.1 Definição

O câncer do colo do útero figura entre as neoplasias malignas mais prevalentes na população feminina global, com maior impacto em países em desenvolvimento, onde se observam altas taxas de incidência e mortalidade. Clinicamente denominado como câncer cervical, essa condição tem sua origem em transformações celulares na região do colo uterino, indicado na Figura 2.5. Do ponto de vista da saúde pública, estratégias de prevenção primária e secundária, associadas ao diagnóstico precoce e intervenções terapêuticas oportunas, constituem elementos fundamentais para a redução da carga de mortalidade associada a esta condição (Ferlay, 2021).

Figura 2.5 – Representação anatômica do colo do útero e suas estruturas.

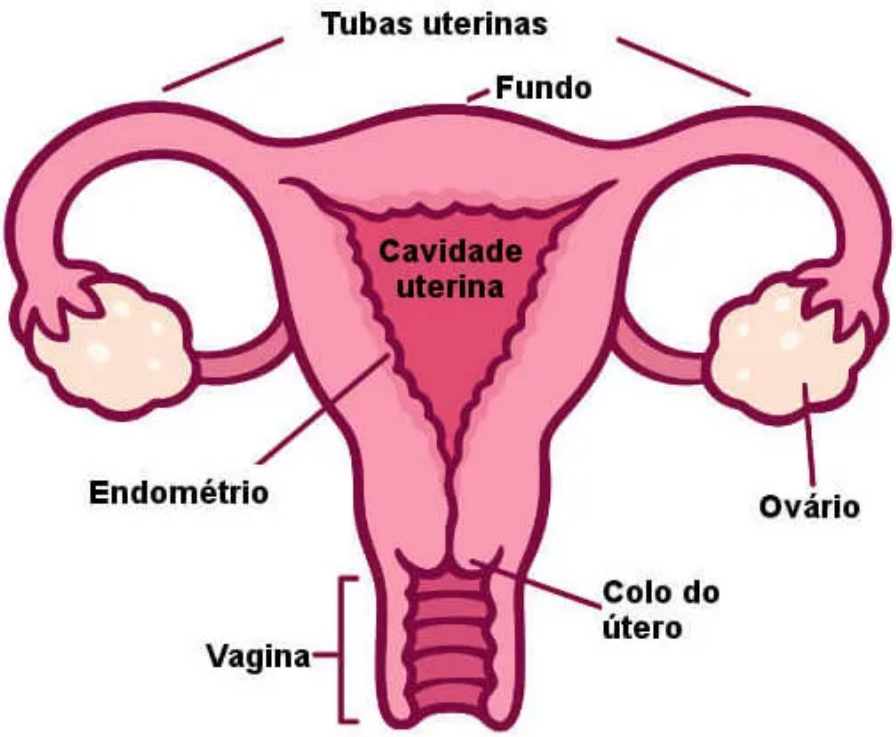

Fonte: SANTOS (2024).

2.3.2 Etiologia e Fatores de Risco

O CCU está diretamente associado à infecção pelo papilomavírus humano (HPV), um grupo de vírus com mais de 100 tipos diferentes, dos quais cerca de 14 são considerados de alto risco e responsáveis pela maioria dos casos de câncer cervical. A transmissão do HPV ocorre predominantemente por contato sexual, sendo a infecção extremamente comum ao longo da vida sexualmente ativa das pessoas. Contudo, na maioria dos casos, o sistema

imunológico elimina o vírus de forma natural, sem causar complicações significativas (OPAS, 2023).

A infecção persistente por tipos de alto risco do HPV pode causar alterações celulares pré-cancerosas que, se não tratadas, podem evoluir para o câncer do colo do útero. Além da infecção pelo HPV, outros fatores contribuem para o aumento do risco de desenvolver o câncer cervical, incluindo o início precoce da atividade sexual, múltiplos parceiros sexuais, tabagismo, imunossupressão e histórico familiar da doença (Dunne; Markowitz, 2006).

2.3.3 Evolução da Doença e Sintomas

O câncer se desenvolve lentamente e, na maioria dos casos, passa por uma fase pré-cancerosa antes de se tornar um câncer invasivo. Essa fase pré-cancerosa é conhecida como Neoplasia Intraepitelial Cervical (NIC), e pode ser classificada em graus que variam de I a III, dependendo do nível de anormalidade das células.

Nos estágios iniciais, o câncer cervical pode ser assintomático, ressaltando a importância de exames preventivos regulares para sua detecção precoce. À medida que a doença avança, podem surgir sintomas como sangramento vaginal anormal, dor durante as relações sexuais e dor pélvica. Se não diagnosticado e tratado precocemente, o câncer pode se espalhar para outras partes do corpo, como bexiga, reto, pulmões e fígado, tornando o tratamento mais complexo e reduzindo significativamente as chances de cura (National Cancer Institute, 2021).

2.3.4 Prevenção

A prevenção pode ser realizada por meio de diferentes estratégias, sendo a vacinação contra o HPV uma das mais eficazes, recomendada principalmente para meninas e meninos entre 9 e 14 anos, isso porque é mais eficiente quando administrada antes do início da atividade sexual, pois garante proteção contra o vírus antes da exposição. Além disso, o uso de preservativos durante as relações sexuais ajuda a reduzir o risco de transmissão do HPV.

Outra medida essencial de prevenção é a realização regular do exame de Papanicolau, recomendado para mulheres entre 25 e 64 anos. Esse exame permite a detecção precoce de alterações celulares que podem ser tratadas antes de evoluírem para câncer (WHO, 2020).

No Brasil, o Ministério da Saúde implementa o Programa Nacional de Prevenção do Câncer do Colo do Útero, baseado em três eixos estratégicos disponíveis na rede de atenção primária: imunização contra o HPV para adolescentes, rastreamento através do exame citopatológico (PCCU), e ações de educação em saúde para a população. Contudo, os dados epidemiológicos revelam uma disparidade regional marcante, com a região Norte apresentando as maiores taxas de incidência e mortalidade - indicativo da necessidade urgente de implementar abordagens inovadoras que complementem as estratégias existentes e potencializem a detecção precoce e a terapêutica adequada (INCA, 2022).

Nesse contexto epidemiológico, a detecção precoce e a intervenção terapêutica imediata assumem papel fundamental para melhorar os desfechos clínicos e elevar as taxas de sobrevida global. Paralelamente, o avanço de soluções tecnológicas inovadoras tem emergido como estratégia complementar para enfrentamento desses desafios. Como paradigma dessa abordagem, o estudo desenvolvido por Debroy (2023) demonstrou a aplicabilidade de algoritmos de machine learning na classificação de vinte diferentes neoplasias malignas,

evidenciando o potencial transformador dessas ferramentas computacionais no apoio à identificação precoce e manejo personalizado de patologias oncológicas.

Diante desse cenário, os algoritmos de machine learning emergem como inovação tecnológica no âmbito do diagnóstico e prognóstico. Sua capacidade de processamento associada à identificação de padrões complexos em bases multimodais possibilita maior velocidade e eficiência na detecção de lesões/alterações.

2.4 Machine Learning

O machine learning é uma subárea da inteligência artificial (IA) que permite aos sistemas aprenderem e melhorarem a partir da experiência, por meio de modelos matemáticos, sem precisar ser explicitamente programados. Em vez de seguir um conjunto fixo de instruções, algoritmos de ML utilizam dados para identificar padrões e fazer previsões ou tomar decisões com base em informações adquiridas. Esse conceito vem revolucionando inúmeras áreas, como a medicina (Hurwitz; Kirsch, 2000).

2.4.1 Tipos de Machine Learning

O machine learning pode ser dividido em três principais tipos:

1. **Aprendizado Supervisionado**: O algoritmo aprende a partir de um conjunto de dados de entrada e saídas conhecidas. O modelo é treinado para mapear as entradas para as saídas corretas. Por exemplo, em um sistema de previsão do preço de imóveis, o algoritmo é treinado com dados históricos de preços de casas, considerando variáveis como localização, tamanho e número de quartos. O objetivo é prever o preço de uma casa nova com base em suas características;
2. **Aprendizado Não Supervisionado**: Não há rótulos nos dados de entrada e tem o objetivo de identificar padrões e estruturas ocultas nos dados. Um exemplo clássico é a análise de agrupamento (clustering), na qual o algoritmo separa os dados em diferentes grupos com base em suas similaridades;
3. **Aprendizado por Reforço**: Inspira-se na maneira como os seres humanos aprendem através de tentativa e erro. Nesse tipo de aprendizado, um agente (o algoritmo) toma ações em um ambiente para maximizar uma recompensa ao longo do tempo. Esse método é amplamente usado em robótica e em jogos, como quando o algoritmo AlphaGo, da Google, aprendeu a vencer jogadores humanos no jogo de Go, fazendo milhões de simulações e ajustando suas estratégias (Gogoni, 2016).

A Figura 2.6 ilustra os diferentes tipos de machine learning e algumas de suas aplicações. Entre essas abordagens, optamos por utilizar o aprendizado supervisionado para tratar o problema em questão, dado que ele é particularmente adequado para conjuntos de dados rotulados. Nesse contexto, cada entrada do banco de dados está associada a uma saída conhecida, permitindo que o modelo identifique padrões e generalize relações entre as variáveis, possibilitando previsões ou classificações de forma precisa e consistente.

Figura 2.6 – Tipos de aprendizado de máquina.

Fonte: Maia (2022).

Com isso, com o tipo de aprendizado definido, serão apresentados os algoritmos clássicos selecionados, que serão implementados e analisados no decorrer deste estudo.

2.4.2 Support Vector Machines (SVM)

Figura 2.7 – Diagrama SVM para duas features.

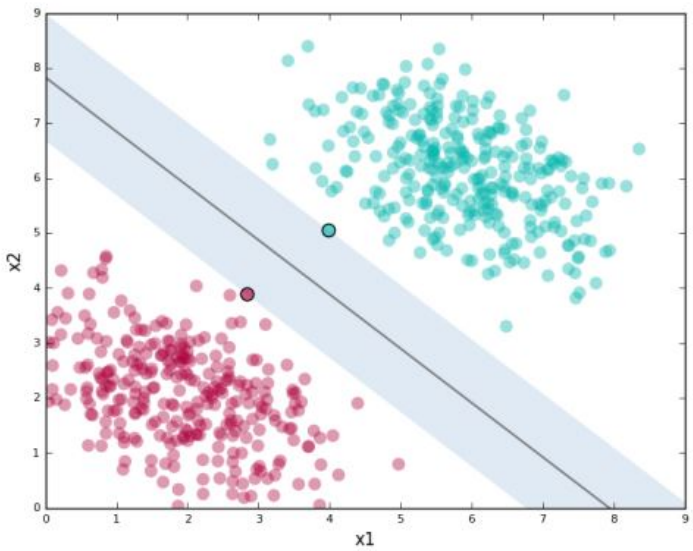

Fonte: Malta e Kuroiva (2019).

A ideia principal por trás do SVM é encontrar um hiperplano que separe os dados de diferentes classes de maneira ideal. Esse hiperplano é uma linha, em duas dimensões, ou um plano, em dimensões mais altas, que maximiza a margem entre as classes de dados. Essa maximização da margem permite que o modelo tenha uma boa generalização e, portanto, um desempenho superior ao lidar com novos dados.

A Figura 2.7 ilustra a inserção de dois novos pontos de dados no espaço de classificação e apresenta o hiperplano que separa as classes. Esse hiperplano atua como uma fronteira decisiva, permitindo classificar os novos dados com base na sua posição relativa às classes previamente definidas.

2.4.3 Logistic Regression (LR)

A Logistic Regression é um método amplamente utilizado para resolver problemas de classificação binária e trata-se de um modelo de classificação e não de regressão, onde a função logística (ou sigmoide) é usada para prever a probabilidade de uma instância pertencer a uma determinada classe. A fórmula sigmoide mapeia valores contínuos para um intervalo entre 0 e 1, que é interpretado como a probabilidade de uma classe específica.

2.4.4 K-Nearest Neighbors (KNN)

O KNN é um modelo de aprendizado supervisionado amplamente utilizado para tarefas de classificação. Seu princípio fundamental baseia-se em classificar um ponto com base nas classes dos seus vizinhos mais próximos. O modelo armazena todos os exemplos disponíveis no treinamento e classifica novos casos utilizando uma métrica de similaridade, como a distância euclidiana.

No KNN, o parâmetro ”K”define o número de vizinhos mais próximos a serem considerados no processo de classificação, sendo recomendado que seja ímpar para evitar empates. Matematicamente, ao inserir um novo ponto no espaço de dados, o modelo calcula a distância entre este ponto e todos os outros, após isso, os K vizinhos mais próximos são selecionados, e a classe majoritária entre eles determina a classificação do novo ponto.

Figura 2.8 – Inserção de novo ponto para K=3.

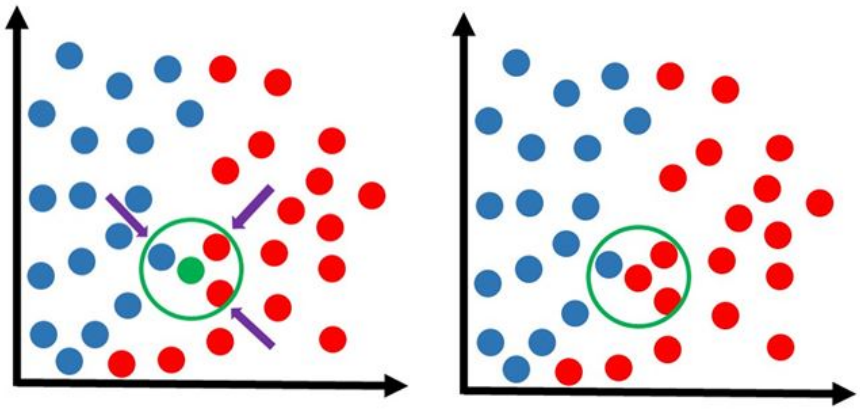

Fonte: Tech (2019).

A Figura 2.8 ilustra a situação em que um novo dado é inserido no espaço de classificação, com o parâmetro k igual a 3. Nesse cenário, os três pontos mais próximos são analisados, e a classe com maior número de amostras entre eles é atribuída ao novo dado.

2.4.5 Naive Bayes (NB)

O NB é um modelo de aprendizado baseado no Teorema de Bayes, que parte da suposição de independência condicional entre as características. Seu princípio fundamental é calcular a probabilidade de uma amostra pertencer a uma classe específica, dado o conjunto de características observadas. Essa abordagem permite que o modelo determine a classe mais provável para cada amostra, mesmo em cenários com muitas variáveis, sendo amplamente utilizado com classificação de textos e detecção de spam.

2.4.6 Decision Tree (DT)/Random Forest (RF)

A Decision Tree é um modelo de aprendizado supervisionado que utiliza uma estrutura hierárquica para tomar decisões. Em cada nó da árvore, ocorre um teste em uma característica do conjunto de dados, e os ramos representam os resultados possíveis desse teste. Esse processo continua de forma recursiva até alcançar um nó folha, que corresponde à previsão final do modelo. Apesar de sua simplicidade e interpretabilidade, as DT isoladas podem sofrer com o overfitting, especialmente ao lidar com conjuntos de dados complexos ou com muitos ruídos. Para mitigar esse problema, técnicas como poda são aplicadas, removendo divisões desnecessárias que não contribuem para a generalização do modelo. Além disso, abordagens baseadas na combinação de múltiplas árvores, como o random forest, aumentam a robustez e a precisão ao integrar os resultados de várias árvores de decisão treinadas de forma independente.

Figura 2.9 – Exemplo de DT para responder ”is a person fit?”.

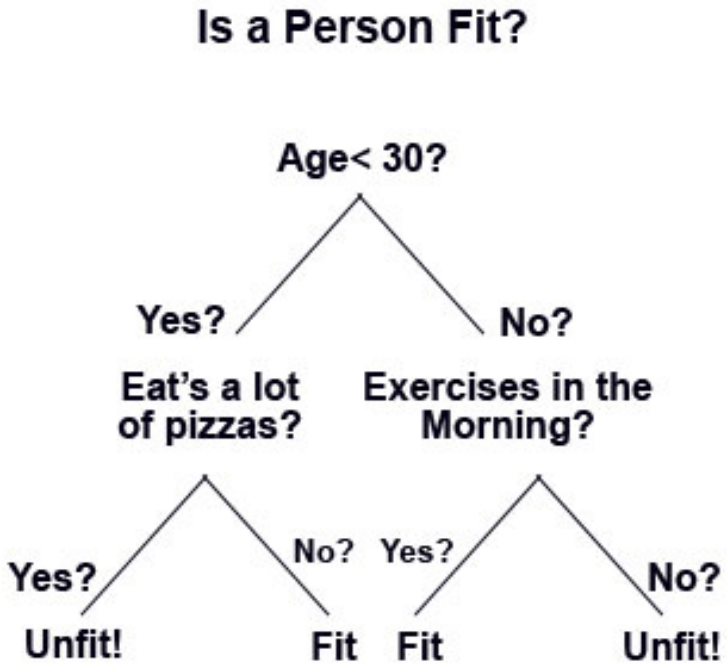

Fonte: Pedamkar (2023).

A Figura 2.9 mostra um exemplo simples do funcionamento de uma Decision Tree. O processo começa com uma questão principal, que é respondida por meio de perguntas subsequentes com opções de ”sim”ou ”não”. Cada resposta leva a novos caminhos, ramificando as possibilidades até alcançar um nó folha, que representa a resposta ou classificação final.

2.5 Métricas

As métricas de desempenho representam instrumentos quantitativos fundamentais para avaliação dos modelos implementados. Nesta seção, apresentam-se as principais medidas de validação adotadas no estudo.

2.5.1 Confusion Matrix

A confusion matrix constitui um instrumento fundamental para avaliação de modelos preditivos, representando uma estrutura tabular que confronta as previsões do modelo com os valores reais, proporcionando assim uma análise multidimensional do desempenho classificatório. Nesta matriz:

1. *True Positives* (TP): correspondem os acertos entre previsões positivas do modelo e observações positivas no conjunto de teste;
2. *True Negatives* (TN): refletem acertos na classificação da classe negativa;
3. *False Positives* (FP): classificações errôneas de instâncias negativas como positivas, o chamado ”Erro Tipo I”;
4. *False Negatives* (FN): falhas na detecção de instâncias positivas, ”Erros Tipo II”, particularmente críticas em classificações de doenças.

A análise desses fatores permite identificar padrões de erro específicos, orientar ajustes para melhorar a robustez do modelo e calcular métricas derivadas essenciais para a tomada de decisão. Particularmente no contexto oncológico, a minimização de False Negatives assume importância vital, dado o potencial impacto em diagnósticos subestimados.

Figura 2.10 – Matriz de confusão binária.

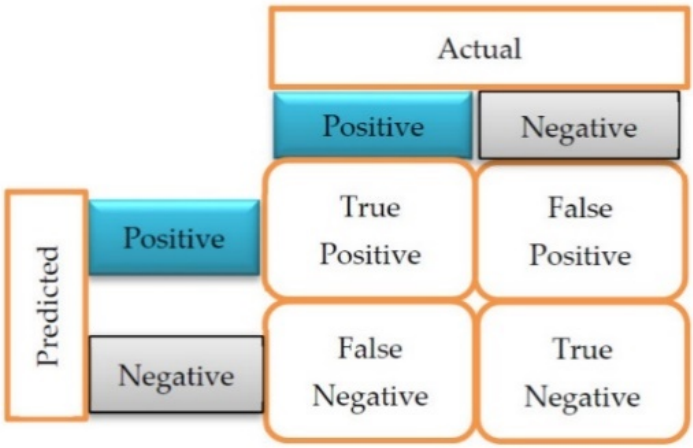

Fonte: Sobar e Adi (2016).

2.5.2 Accuracy

O parâmetro de desempenho mais utilizado e mais conhecido para modelos de classificação é a accuracy, que quantifica a proporção de previsões corretas feitas pelo modelo em relação ao total de previsões, indicando a frequência com que o modelo classifica corretamente as instâncias. Para calcular, utiliza-se a seguinte Equação (2.1):

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{2.1}$$

2.5.3 Precision

A precision é uma métrica de desempenho fundamental em modelos de classificação, especialmente em cenários com classes desbalanceadas. Ela mede a proporção de previsões positivas corretas em relação ao total de previsões positivas realizadas pelo modelo. Uma alta precision indica que o modelo comete poucos erros ao classificar a classe positiva, o que é particularmente relevante em contextos em que os falsos positivos acarretam consequências significativas.

No entanto, a precision, por si só, não é suficiente para fornecer uma visão completa do desempenho do modelo, pois não considera os falsos negativos. Por essa razão, é essencial combiná-la com outras métricas, como a recall ou a f1-Score, para obter uma avaliação mais abrangente. A fórmula para calcular a precision é apresentada na Equação (2.2):

$$precision = \frac{TP}{TP + FP} \tag{2.2}$$

2.5.4 Recall

O recall mede a capacidade do modelo de detectar corretamente todos os casos positivos, calculado conforme a Equação (2.3).

$$recall = \frac{TP}{TP + FN} \tag{2.3}$$

Essa métrica é especialmente crítica em diagnósticos médicos, pois está diretamente relacionada à minimização de falsos negativos, casos em que pacientes doentes são erroneamente classificados como saudáveis. No contexto do câncer cervical, maximizar o recall significa reduzir o risco de deixar passar casos positivos da doença.

2.5.5 F1-score

O f1-score é uma métrica de desempenho que calcula a média harmônica entre precision e recall, Equação (2.4), proporcionando uma única métrica que equilibra ambas, o que se mostra útil em cenários onde há um desequilíbrio entre as classes ou onde tanto os falsos positivos quanto os falsos negativos têm consequências significativas.

$$f_1 = \frac{2 * accuracy * recall}{(accuracy + recall)} \tag{2.4}$$

2.6 Tomada de Decisão Multicritério

A Tomada de Decisão Multicritério, conhecida pela sigla MCDM (Multi-Criteria Decision Making), é uma abordagem que auxilia na tomada de decisões complexas e seu

fundamento está na ideia de que as decisões raramente são simples e unidimensionais, pois, na maioria dos cenários, vários critérios precisam ser avaliados simultaneamente e, frequentemente, entram em conflito. O processo de decisão requer uma análise cuidadosa para selecionar uma ou mais alternativas, dependendo da técnica escolhida para uso.

A MCDM é amplamente utilizada em diversas áreas, como engenharia, economia, planejamento urbano, gestão ambiental, saúde pública e tecnologia. Nesse sentido, onde exista alguma decisão a ser tomada, pode-se aplicar alguma das várias técnicas existentes de tomada de decisão (Buani; Suryani, 2022).

Existem diversos métodos de MCDM, alguns dos mais conhecidos incluem o AHP, TOPSIS, VIKOR, ELECTRE e PROMETHEE, os quais podem ser usados para estruturar e resolver problemas complexos, desde a soma simples de valores, como no cenário de eleições, até o uso de fórmulas matemáticas complexas, exemplo da seleção de fornecedores. Cada método possui suas próprias particularidades e aplicações, logo, é necessário possuir domínio sobre o cenário de aplicação para selecionar o modelo que melhor resolve o problema de decisão.

Este Trabalho de Conclusão de Curso (TCC) propõe uma abordagem multicritério integrando os métodos AHP e TOPSIS para apoio à tomada de decisão. Na fase inicial, o AHP será utilizado para estruturar a hierarquia de critérios, realizar comparações pareadas entre elementos e calcular os pesos relativos de cada critério. Esses pesos serão então aplicados, como entrada, no método TOPSIS que avaliará as alternativas mediante cálculo de distâncias euclidianas em relação às soluções ideal e anti-ideal, gerando um ranking objetivo que subsidiará a seleção da melhor opção.

2.6.1 AHP

Figura 2.11 – Estrutura Hierárquica do Método AHP.

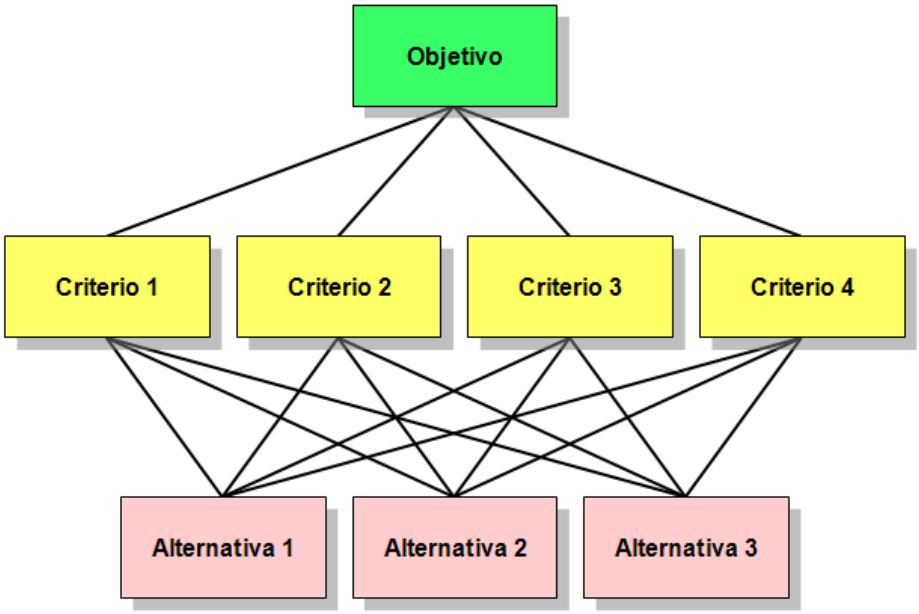

Fonte: Santos et al. (2017).

O AHP (Analytic Hierarchy Process) ou Processo de Hierarquia Analítica, desenvolvido por Thomas L. Saaty na década de 1970, é um dos métodos mais populares e

amplamente utilizados. O AHP fornece uma estrutura para organizar e analisar decisões complexas com múltiplos critérios. Ele faz a avaliação e comparação dos critérios pareados, gerando uma matriz de julgamento, a partir da qual são derivados os pesos para cada critério, em seguida, usa-se esses pesos para avaliar as alternativas disponíveis.

De modo mais específico, o AHP é realizado em seis etapas:

1. **Definição do Problema e Estruturação da Hierarquia**: Identificar o objetivo, os critérios e as alternativas possíveis e estruturar esses elementos em uma hierarquia.
2. **Comparações Par a Par**: Utilizando a escala de importância relativa, conforme Tabela 2.1, atribui-se a importância dos critérios e/ou alternativas em relação aos outros.

Tabela 2.1 – Escala de importância relativa.

Valor	Importância Relativa	Descrição
1	Igual importância	Dois critérios contribuem igualmente para o objetivo
3	Importância moderada	Experiência e julgamento favorecem um critério sobre o outro
5	Importância forte	Experiência e julgamento favorecem fortemente um critério sobre o outro
7	Importância muito forte	Um critério é muito fortemente favorecido em relação ao outro
9	Importância extrema	Um critério é de maior ordem possível favorecido em relação ao outro
2,4,6,8	Importância entre intervalos	Critério entre intervalos de importância

Fonte: Elaborado pelo autor.

3. **Cálculo dos Pesos**: A partir da matriz de comparação, calcula-se os pesos relativos de cada critério. Cada elemento a_{ij} na matriz representa a importância do critério i em relação ao critério j. Os pesos w_i podem ser determinados pela média geométrica da linha da matriz:
$$w_i = \frac{\prod_{j=1}^{n} a_{ij}^{1/n}}{\sum_{i=1}^{n} \prod_{j=1}^{n} a_{ij}^{1/n}} \tag{2.5}$$
   a) w_i é o peso do critério i.
   b) a_i é valor de importância do critério i em relação ao critério j.
4. **Verificação de Consistência**: Avaliar a consistência dos julgamentos feitos, utilizando o índice de consistência CI e a razão de consistência CR. O índice de consistência é dado por:
$$CI = \frac{\lambda_{\max} - n}{n - 1} \tag{2.6}$$
   onde $\lambda_{\max}$ é o maior autovalor da matriz de comparação e n é o número de critérios. A razão de consistência CR é então calculada como:
$$CR = \frac{CI}{RI} \tag{2.7}$$
   onde RI é o índice de consistência aleatória, determinado pela ordem da matriz. Se o CR for menor que 0,1 (10%), a matriz é considerada consistente, caso contrário, será necessário revisar os valores atribuídos aos critérios inicialmente.

Tabela 2.2 – Valores de RI para diferentes quantidades n.

n	1	2	3	4	5	6	7	8	9	10
RI	0	0	0,58	0,90	1,12	1,24	1,32	1,41	1,45	1,49

Fonte: Elaborado pelo autor.

5. **Comparação das Alternativas**: Para cada critério, comparar as alternativas de forma par a par e calcular os pesos das alternativas em relação a cada critério, seguindo o mesmo processo das comparações par a par para critérios.
6. **Cálculo da Pontuação Global**: Multiplicar os pesos das alternativas pelos pesos dos critérios e somar para obter uma pontuação global para cada alternativa. A pontuação global S_i para a alternativa i é dada por:

$$S_i = \sum_{j=1}^{n} w_j \cdot a_{ij} \tag{2.8}$$

As etapas descritas constituem o método AHP em sua totalidade, no entanto, para o caso específico deste estudo, o procedimento pode ser simplificado seguindo até a etapa de verificação de consistência. Essa simplificação se justifica, pois a verificação de consistência é essencial para assegurar a confiabilidade dos julgamentos nas comparações entre critérios, garantindo que o cálculo dos pesos seja robusto e coerente com o objetivo de decisão.

2.6.2 TOPSIS

O TOPSIS (Technique for Order Preference by Similarity to Ideal Solution) é um método de decisão multicritério que classifica alternativas com base em sua proximidade com a solução ideal positiva e seu distanciamento da solução ideal negativa. O objetivo é selecionar a alternativa que esteja mais próxima da solução ideal positiva, enquanto se mantém o mais distante possível da solução ideal negativa. Desenvolvido por Hwang e Yoon em 1981, o TOPSIS destaca-se por sua simplicidade, eficiência e ampla aplicabilidade em diversas áreas, sendo especialmente útil em cenários que envolvem múltiplos critérios de decisão.

O método TOPSIS incorpora entradas numéricas que representam os pesos relativos de cada critério na tomada de decisão. Para ilustrar essa abordagem, existe o exemplo clássico da seleção de um veículo: ao avaliar critérios como consumo de combustível, conforto, preço e reputação da marca, diferentes compradores atribuirão pesos distintos conforme suas prioridades individuais, sendo o preço frequentemente o fator determinante (PACHECO, 2016).

Diante dessa necessidade de precisão na ponderação de critérios, o método AHP surge como ferramenta fundamental, fornecendo base de entrada metodológica para o TOPSIS ao calcular os pesos de cada critério.

As etapas do processo decisório do TOPSIS são as seguintes:

1. **Construção da Matriz de Decisão**: A primeira etapa é construir uma matriz de decisão D, onde cada linha representa uma alternativa e cada coluna um critério. Essa matriz é normalizada para garantir que todas as variáveis estejam em uma mesma escala. A normalização é realizada com a Equação (2.9):

$$r_{ij} = \frac{x_{ij}}{\sqrt{\sum_{i=1}^{n} x_{ij}^2}} \tag{2.9}$$

onde r_{ij} é o valor normalizado do critério j para a alternativa i, e x_{ij} é o valor original.

2. **Construção da Matriz Ponderada**: Após a normalização, cada critério é multiplicado por seu respectivo peso, usando a Equação (2.10) para obter a matriz ponderada v,

$$v_{ij} = w_j \cdot r_{ij} \tag{2.10}$$

onde w_j é o peso do critério j.

3. **Determinação de A* e A-**: A solução ideal positiva A^* contém os melhores valores (máximos para critérios de maximização e mínimos para critérios de minimização), enquanto a solução ideal negativa A^- contém os piores valores. Para cada critério:
4. **Cálculo da Distância Euclidiana**: Em seguida, calcula-se a distância Euclidiana de cada alternativa em relação à solução ideal positiva A^* e à solução ideal negativa A^-. A distância Euclidiana é dada por:

$$d_i^* = \sqrt{\sum_{j=1}^{m} (v_{ij} - v_j^*)^2} \tag{2.11}$$

$$d_i^- = \sqrt{\sum_{j=1}^{m} (v_{ij} - v_j^-)^2} \tag{2.12}$$

onde d_i^* é a distância da alternativa i para a solução ideal e d_i^- é a distância para a solução negativa.

5. **Cálculo do Índice de Similaridade**: O índice de similaridade C_i^* de cada alternativa à solução ideal positiva é calculado por meio da Equação (2.13):

$$C_i^* = \frac{d_i^-}{d_i^* + d_i^-} \tag{2.13}$$

O valor C_i^* varia entre 0 e 1, onde 1 indica a alternativa mais próxima da solução ideal e 0 a mais distante.

6. **Classificação das Alternativas**: As alternativas são classificadas com base no valor de C_i^*. A alternativa com o maior valor de C_i^* é considerada a melhor solução.

3 TRABALHOS RELACIONADOS

A literatura acadêmica apresenta diversas contribuições significativas relacionadas ao câncer, com destaque para os avanços tecnológicos voltados à sua detecção por meio de técnicas de Machine Learning e à melhoria na qualidade dos dados utilizados. Nesta seção, são descritos e analisados alguns desses estudos, destacando métodos inovadores e suas aplicações práticas no contexto do diagnóstico precoce.

3.1 Técnicas de Reamostragem

Um conjunto de dados é desequilibrado se as categorias de classificação não forem igualmente representadas. Frequentemente, conjuntos de dados retirados de situações reais são predominantemente compostos de amostras "normais" com apenas uma pequena porcentagem de amostras "anormais". Esse desequilíbrio dá origem ao problema de desbalanceamento de classe, que pode fazer com que o treinamento seja enviesado para a classe maioritária (Prati; Batista; Monard, 2009). Para contornar este problema, numerosos estudos demonstraram um melhor desempenho de previsão com dados balanceados, portanto, vários métodos foram desenvolvidos e usados em ML para lidar com esse empecilho (Alghamdi et al., 2017).

3.1.1 Subamostragem

A subamostragem é uma técnica utilizada para equilibrar a distribuição de classes em conjuntos de dados desbalanceados, por meio da exclusão de amostras da classe majoritária. O processo consiste na remoção aleatória de dados da classe dominante até que o número de amostras dessa classe se iguale ao da classe minoritária (Rastgoo et al., 2016).

3.1.2 Sobreamostragem

Em contraste a subamostragem, na sobreamostragem são geradas novas amostras pertencentes à classe minoritária até o momento em que ocorre o equilíbrio. A sobreamostragem é referida como uma técnica cujo objetivo é equilibrar a distribuição da classe com a ajuda da replicação aleatória de amostras da classe minoritária. Este método tende a duplicar os dados já disponíveis ou gerar dados com base nos dados disponíveis. A principal desvantagem desta técnica é que as amostras sintéticas criadas fazem com que os classificadores criem regiões de decisão maiores e menos específicas, em vez de regiões menores e mais específicas (Somasundaram; Reddy, 2016).

3.1.3 Híbrido

Vários estudos propuseram técnicas de amostragem híbrida, que combinam métodos de sobreamostragem e subamostragem, para gerar conjuntos de dados equilibrados. Um exemplo amplamente utilizado é o SMOTETomek, uma abordagem híbrida que combina o método de sobreamostragem Synthetic Minority Oversampling Technique (SMOTE) com o método de subamostragem Tomek.

O SMOTE funciona ao gerar amostras sintéticas para a classe minoritária, posicionando-as ao longo dos segmentos de linha que conecta uma amostra da classe

minoritária aos seus vizinhos mais próximos (Colak et al., 2017). Paralelamente, o método Tomek identifica e remove amostras sobrepostas ou ruidosas na fronteira entre classes, melhorando a separabilidade e reduzindo os conflitos gerados durante o processo (More, 2016).

Estudos que utilizaram o SMOTETomek relataram resultados favoráveis no balanceamento da distribuição de classes. A pesquisa de Goel et al. (2013) avaliou cinco técnicas de reamostragem: SMOTE, Adaptive Synthetic, Borderline-SMOTE, SMOTETomek e RUSBoost, utilizando oito conjuntos de dados distintos. Os resultados indicaram que, para a maioria dos casos analisados, o SMOTETomek foi capaz de melhorar a precisão do modelo ao equilibrar as classes de forma mais eficaz.

A escolha do método SMOTETomek para o balanceamento das classes, embora seja uma combinação poderosa, não está isenta de limitações. Uma crítica pertinente à técnica é sua potencial propensão a amplificar ruídos e vieses pré-existentes no conjunto de dados original. Como o SMOTE gera instâncias sintéticas, eventuais outliers ou amostras erroneamente rotuladas podem servir de base para a criação de pontos de dados que não representam a distribuição real, propagando assim imprecisões. Por esse motivo, é necessário construir um caminho de análises antes de aplicar o método verificando a existência de outliers, dados ausentes, duplicados ou nulos.

3.2 Técnicas de Seleção Features

A seleção de features representa a principal abordagem para redução de dimensionalidade em conjuntos de dados complexos, sendo amplamente utilizada quando se trabalha com um grande número de variáveis preditoras (Ali et al., 2020). Esta técnica atua identificando e mantendo apenas as características mais relevantes para a predição da variável-alvo, o que traz benefícios significativos para o processo de modelagem.

Ao aplicar a seleção de features, observa-se uma melhoria no poder preditivo dos algoritmos de classificação, juntamente com uma redução no tempo de processamento e nos custos computacionais envolvidos. Como demonstrado por Alghamdi et al. (2017), a redução adequada de dimensionalidade pode levar a melhorias perceptíveis no desempenho dos modelos de aprendizado de máquina. Além disso, essa abordagem permite eliminar variáveis irrelevantes ou redundantes, reduzir o ruído nos dados e produzir modelos mais confiáveis e generalizáveis, já que um menor número de características participa do processo de treinamento.

As técnicas de seleção de features podem ser categorizadas em três grupos principais: filter, wrapper e embedded

3.2.1 Filter

Nos métodos de filter, as features são selecionados com base em sua correlação com a variável-alvo por meio de testes estatísticos, os quais são aplicados, principalmente, antes da classificação para filtrar as variáveis menos relevantes (Chandrashekar; Sahin, 2014). Eles são consideravelmente mais rápidos e usam menos recursos computacionais do que todas as outras técnicas de seleção (Sanchez-Marono; Alonso-Betanzos; Tombilla-Sanroman, 2007). O problema com a técnica é que ela não interage com outros recursos e não considera o modelo que está sendo empregado (Nithya; Ilango, 2019).

O teste qui-quadrado é o método de filter que faz a seleção por meio da pontuação qui-quadrado, calculada para cada variável de entrada em relação à variável-alvo. Esse tipo de seleção é mais comum em dados estruturados, contendo características categóricas.

A correlação de Pearson é outro exemplo do método e é indicada para uso quando um Dataset possui diversas variáveis de entrada independentes correlacionadas. O coeficiente de correlação é calculado para cada variável de entrada em relação as outras variáveis. O processo baseado neste método consiste em eliminar uma das variáveis quando se identifica alta correlação, mantendo assim apenas os atributos mais informativos.

3.2.2 Wrapper

Neste método, um subconjunto dos dados é usado para treinar o modelo e conforme interferências obtidas no modelo anterior, um subconjunto com menos interferência é selecionado. Os métodos wrapper podem detectar a interação que ocorre entre os diferentes recursos no conjunto de dados e geralmente têm um melhor desempenho preditivo do que os métodos de filter. Assim, ele mede a eficácia de um subconjunto de recursos por meio do treinamento de um modelo aplicado a ele. Portanto, esses métodos são computacionalmente mais altos (Peng; Wu; Jiang, 2010).

O RFE destaca-se como uma técnica robusta para seleção de features, operando através de um processo iterativo que elimina progressivamente as características menos relevantes. Este método baseia-se no desempenho do modelo para identificar e reter apenas as variáveis preditoras que mais contribuem para a accuracy preditiva da variável-alvo (Chen; Jeong, 2007).

3.2.3 Embedded

O método embedded combina características dos métodos de filter e wrapper para realizar a seleção de um subconjunto ideal de recursos. Apesar de selecionar características específicas do modelo, ele apresenta vantagens significativas em relação aos métodos anteriores. Entre elas, destaca-se o menor consumo de recursos computacional, maior precisão em comparação ao método de filter e a capacidade de considerar todos os recursos simultaneamente no processo de seleção (Rodriguez-Galiano et al., 2018).

Uma das técnicas de seleção é a LASSO. Ela fornece um meio para seleção eficiente de recursos com base na suposição de dependência linear entre recursos de entrada e recursos de saída (Yamada et al., 2014). Os autores Ghosh et al. (2021) desenvolveram um modelo ML para prever doenças humanas cardiovasculares e como parte do processo, características relevantes foram selecionadas usando o LASSO. A análise dos resultados mostrara a métrica precision com 97,65%, atribuindo esse valor à etapa de seleção de features.

O método de seleção baseado em decision tree também pertence à categoria de técnicas embedded. Esse método realiza a seleção de variáveis ao mesmo tempo que constrói o modelo, combinando elementos dos métodos filter e wrapper, utilizando métricas como Gini index ou Entropia para avaliar e escolher features que melhor dividem os dados em cada nó, priorizando as variáveis mais relevantes de forma hierárquica (Breiman et al., 1984).

O grupo de pesquisadores Gayatri, Nickolas e Reddy (2010), propõe um método de seleção de features usando decison tree para melhorar a previsão de defeitos em software. O foco do trabalho está em utilizar a redução de recursos em um conjunto de dados e identificar atributos significativos que podem ser usados para prever a ocorrência de defeitos em módulos de software. O estudo conclui que o uso de DT para a seleção melhora a accuracy do modelo preditivo, facilitando a criação de sistemas de previsão de defeitos mais confiáveis e eficazes.

Em outro estudo, apresentado por Xinying Shu (2022), foram analisados dois métodos de seleção de features embeddeds, ambos baseados em redes neurais. Esses métodos foram aplicados a um conjunto de dados referentes ao futebol europeu, com o objetivo de simular características mais relevantes para a modelagem e análise de desempenho. A pesquisa destacou as vantagens e limitações de cada abordagem, contribuindo para um melhor entendimento do impacto da seleção de features.

3.3 Classificação do Câncer Cervical

Ao longo dos anos, uma grande quantidade de dados foi coletada e está acessível aos pesquisadores, incluindo informações relacionadas à área médica, principalmente sobre doenças. No caso específico do câncer do colo do útero, diversas iniciativas têm explorado o uso de técnicas de machine learning para auxiliar na sua detecção (William et al., 2018). Nesse contexto, alguns trabalhos anteriores também utilizaram o mesmo conjunto de dados selecionado para este estudo. O dataset será descrito detalhadamente na próxima seção.

A equipe Choudhury, Wesabi e Won (2018) investigou vários classificadores de ML, como naive bayes, decision tree, logistic regression, KNN e SVM para classificar pacientes com câncer cervical. Foi perceptível que o classificador DT superou os demais classificadores com uma precision de 92.60% apesar de não haver seleção de features. A limitação encontrada ocorreu por causa do overfitting do modelo (caso em que o modelo aprende excessivamente os detalhes e os ruído dos dados de treinamento).

O pesquisador Singh (2018) usou SVM, random forest e Gradient Boosting Machine (GBM) com a técnica de SMOTE. Eles também aplicaram o algoritmo genético (GA) para seleção de recursos e otimização bayesiana para ajuste de hiperparâmetros, além da observação do recall para eleger o melhor algoritmo. Seus resultados mostraram que o GBM teve recall de 77.8%, seguido pelo SVM com 55.58% e RF com 44.4%. No entanto, os resultados podem ser melhorados para atingir excelente desempenho do modelo.

A equipe Ijaz, Attique e Son (2020) desenvolveu um modelo de predição de câncer cervical usando um conjunto de dados de fatores de risco. O modelo elimina outliers aplicando duas técnicas de detecção, o agrupamento espacial baseado em densidade de aplicações com ruído (DBSCAN) e floresta de isolamento (iForest). Eles também aplicaram o SMOTETomek para reamostrar o conjunto de dados de fatores de risco de câncer cervical e, por fim, empregaram a RF como o classificador favorito frente a outros testados.

O estudo de Ali et al. (2024), para realizar uma análise mais abrangente em relação aos demais trabalhos, verificou dois datasets com o tema de câncer do colo do útero, um sobre comportamentos que podem estar ligados ao surgimento de câncer e outro sobre dados médicos de pacientes, ambos com diversas features, respectivamente, 20 e 36, além de usar diferentes técnicas de aprendizado supervisionado. O trabalho alcançou o resultado almejado, no entanto, algumas decisões podem ser questionadas, como o não tratamento da classe minoritária, o uso de todas as features de um dos datasets, seleção de features de apenas um dataset e julgamento de qual técnica de machine learning obteve melhor resultado observando apenas a accuracy, apesar de desenvolver e exibir os valores de outras métricas.

O grupo de pesquisadores Tanimu et al. (2022) trabalhou com o dataset da UCI Machine Learning Repository, utilizou o SMOTETomek para igualar as amostras e, para seleção de features, usou dois métodos, o LASSO e o RFE, escolhendo as 10 primeiras features importantes e realizou o treinamento apenas com o algoritmo DT, pois observou em uma série de artigos acadêmicos que a decision tree possuía os maiores valores gerais nas métricas e, também, seu objetivo era verificar como a seleção de recursos era importante

para a eficácia do algoritmo. A conclusão foi de que, ao comparar o treinamento sem método de seleção com os dois métodos, as métricas da DT foram maiores com o uso da seleção, destacando o método RFE com accuracy de 97.42%.

O pesquisador Fatlawi (2017) diante de quatro variáveis-alvo, presentes no dataset da UCI, optou por fazer a junção delas em uma única variável, de modo que a nova coluna nomeada *Cancer* varie de 0 até 4, sendo uma multivariável. Além disso, para diminuição da dimensionalidade, realizou a seleção de features e utilizou a decision tree e uma variante da DT para treinar o modelo. Os resultado obtidos foram todos abaixo de 50% nas métricas observadas.

A equipe Deng, Luo e Wang (2018) separou as quatro variáveis-alvo e realizou quatro treinamentos distintos com os algoritmos SVM, RF e XGBoost (eXtreme Gradient Boosting), além de aplicar a reamostragem com Borderline-SMOTE. Contudo, não houve seleção de features, apenas foram excluídas as linhas com mais valores nulos. O treinamento ocorreu com ótimos resultados para as métricas accuracy, precision, recall e f1-score, com RF destacando-se sobre os demais, obtendo accuracy máxima de 97%.

É evidente a falta de consenso quanto às métricas prioritárias para avaliação de algoritmos. Enquanto alguns pesquisadores privilegiam a accuracy como medida principal, outros enfatizam a precision ou o recall, conforme os requisitos específicos de cada estudo. Essa divergência metodológica pode comprometer a comparabilidade dos resultados entre diferentes pesquisas.

Como estratégia para superar essas incompatibilidades, técnicas multicritério de tomada de decisão têm se mostrado particularmente promissoras. O trabalho dos pesquisadores Akdag, Menekse e Sahin (2024) demonstrou a eficácia da integração entre o método TOPSIS e modelos de ML, aplicando essa abordagem para identificar os fatores de risco mais significativos associados ao desenvolvimento do câncer cervical.

Contudo, o MCDM pode ser aplicado em diversos contextos médicos, como outros tipos de câncer. O trabalho de Mustapha et al. (2022) realizou um estudo voltado para a predição de câncer de mama, fazendo uma abordagem abrangente para determinar, conforme métodos adotados, qual seria a técnica de machine learning que melhor se adequava para dez critérios de decisão. O método MCDM usado foi o PROMETHEE, o qual permitiu ordenar os melhores algoritmos, elegendo o SVM como mais adequado.

O estudo de Ali e Broumi (2024) adotou um modelo de sistema de decisão que inclui machine learning e tomada de decisão multicritério para previsão e análise do câncer de tireoide. Três algoritmos, LR, SVM e RF, foram considerados no artigo, os quais tiveram vantagens e desvantagens em determinadas métricas, com isso, o método TOPSIS é aplicado para classificar os algoritmos de ML, o qual elegeu o SVM como modelo mais adequado para tarefa em questão.

Apesar do crescente foco no desenvolvimento de modelos preditivos baseados em machine learning para doenças, especialmente no câncer do colo do útero, poucos estudos abordam de forma integrada a seleção de features, o tratamento de classes desbalanceadas e a seleção do melhor algoritmo com base em múltiplas métricas de desempenho. Diante dessa lacuna, nossa pesquisa propõe um modelo para predição de CCU que combina técnicas avançadas de machine learning com métodos de tomada de decisão multicritério. A abordagem inclui um tratamento de dados robusto por meio de reamostragem híbrida e uma seleção eficiente de features utilizando o método embedded.

Tabela 3.1 – Comparação de características de diferentes abordagens para detecção de câncer cervical e nossa proposta.

Autores	**Dataset**	**Seleção de Features**	**Reamostragem**	**N Algoritmos**	**MCDM**
Choudhury, Wesabi e Won (2018)	✓		✓	✓	
Singh (2018)	✓	✓	✓	✓	
Ijaz, Attique e Son (2020)	✓	✓	✓	✓	
Ali et al. (2024)	✓	✓		✓	
Tanimu et al. (2022)	✓	✓	✓		
Fatlawi (2017)	✓	✓			
Deng, Luo e Wang (2018)	✓		✓	✓	
Akdag, Menekse e Sahin (2024)	✓	✓			✓
Mustapha et al. (2022)				✓	✓
Ali e Broumi (2024)				✓	✓
Nossa Proposta	✓	✓	✓	✓	✓

Fonte: Elaborado pelo autor.

4 MATERIAIS E MÉTODOS

A presente pesquisa caracteriza-se como um estudo aplicado, de natureza quantitativa e exploratória, cujo objetivo é analisar e selecionar o algoritmo de machine learning mais adequado para a predição do câncer cervical a partir de bases de dados reais. Trata-se de uma investigação experimental, pois envolve a aplicação de técnicas computacionais sobre um conjunto de dados estruturados, com o intuito de testar, avaliar e comparar diferentes modelos sob múltiplos critérios de desempenho.

O estudo fundamenta-se em três pilares metodológicos principais: (i) a utilização de dados clínicos e epidemiológicos referentes ao câncer cervical, obtidos em bases públicas; (ii) a aplicação de algoritmos de aprendizado de máquina supervisionado, de modo a identificar padrões e prever a ocorrência da doença; e (iii) a integração de métodos de Tomada de Decisão Multicritério, especificamente o AHP e o TOPSIS, que possibilitam avaliar os modelos não apenas por uma métrica isolada, mas considerando simultaneamente diferentes indicadores de desempenho, aumentando a robustez do processo decisório. A Figura 4.1 apresenta de forma esquemática o fluxo metodológico adotado na pesquisa.

Figura 4.1 – Etapas do processo de dados.

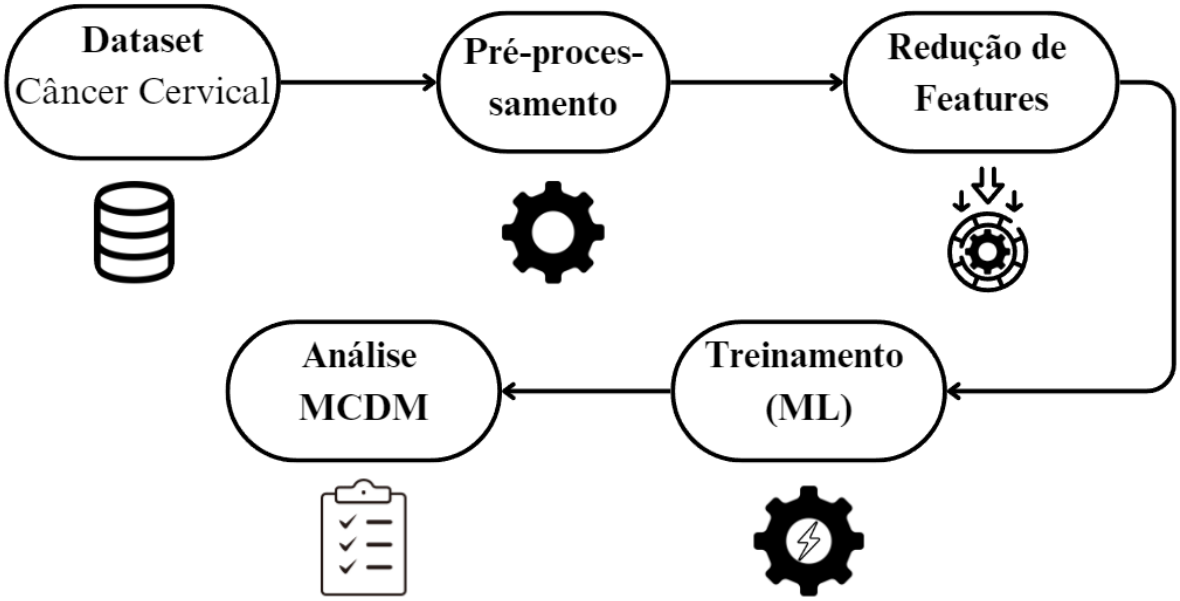

Fonte: Elaborado pelo autor.

4.1 Conjunto de Dados

O conjunto de dados de câncer cervical utilizado neste estudo teve origem em um hospital de Caracas, na Venezuela, disponível publicamente no UCI Machine Learning Repository, (Fernandes; Cardoso; Fernandes, 2017). Ele contém 36 atributos no total, dos quais 32 correspondem a características relacionadas a dados médicos sobre o câncer do colo do útero e 4 são variáveis-alvo, além disso, o dataset possui 836 instâncias, onde cada instância representa uma paciente do hospital. As variáveis-alvo, por sua vez, referem-se a quatro diferentes exames capazes de identificar alterações uterinas: *Hinselmann*, *Schiller*, *Citology* e *Biopsy*, sendo a biópsia o exame mais conhecido. O rótulo de classe

é binário, com 0 indicando a ausência de alterações e 1 indicando a presença de alterações. A Tabela 4.1 apresenta o conjunto completo de variáveis do estudo, especificando para cada feature seu respectivo tipo de dado.

Tabela 4.1 – Tipos das features originais do dataset.

Nº	**Coluna**	**Tipo**	**Nº**	**Coluna**	**Tipo**
1	Age	int	2	Sex partners	int
3	1st intercourse	int	4	Pregnancies	int
5	Smokes	boolean	6	Smoke yrs	int
7	Smoke packs/yr	int	8	Hormonal Contr	boolean
9	Hormonal yrs	int	10	IUD	boolean
11	IUD yrs	int	12	STDs	boolean
13	STD num	int	14	Condylomatosis	boolean
15	Cervical Condylom	boolean	16	Vaginal Condylom	boolean
17	Vulvo-Condylom	boolean	18	Syphilis	boolean
19	PID	boolean	20	Genital Herpes	boolean
21	Molluscum	boolean	22	AIDS	boolean
23	HIV	boolean	24	Hepatitis B	boolean
25	HPV	boolean	26	STD diag num	int
27	1st diag time	int	28	Last diag time	int
29	Dx: Cancer	boolean	30	Dx: CIN	boolean
31	Dx: HPV	boolean	32	Dx	boolean
33	Hinselmann	boolean	34	Schiller	boolean
35	Citology	boolean	36	Biopsy	boolean

Fonte: Elaborado pelo autor.

Embora o conjunto de dados seja amplamente reconhecido e adequado para os objetivos desta pesquisa, é importante salientar uma limitação inerente ao seu uso: a escassez na literatura de datasets públicos alternativos com características semelhantes para o problema de predição de risco de câncer cervical. A grande maioria dos conjuntos de dados disponíveis na área de oncologia são voltados para tarefas de Deep Learning, como a análise de imagens histopatológicas, os quais demandam alto poder computacional.

Em contraste, o dataset escolhido, com seus 36 atributos, é singular por ser estruturado e tabular, permitindo a aplicação e comparação de algoritmos clássicos de machine learning. Portanto, apesar de sua dimensão amostral limitada, que restringe a generalização dos resultados, a base selecionada é a mais adequada, pois fornece um panorama abrangente e acessível sobre os fatores de risco clinicamente relevantes para a doença.

4.1.1 Pré-processamento

O pré-processamento de dados é uma das etapas mais significativas em machine learning e mineração de dados, pois melhora a qualidade dos dados e, consequentemente, o desempenho dos modelos de ML (Sobar; Adi, 2016). Logo, o conjunto de dados possui algumas peculiaridades para serem contornadas, como: quatro variáveis-alvo, normalização, valores nulos, número de features e desbalanceamento das classes.

4.1.1.1 Variáveis-Alvo

As quatro variáveis-alvo representam os resultados de diferentes exames clínicos utilizados no diagnóstico do câncer cervical, cada um com métodos específicos para detectar alterações. É possível que um exame não identifique a presença de câncer enquanto outro o detecte, gerando diferentes possibilidades de análise. Entre as alternativas estão: trabalhar exclusivamente com a variável *Biopsy*, excluindo as demais; combinar todas as variáveis em uma única variável-alvo; ou utilizar cada uma das variáveis separadamente, sem exclusão.

A opção selecionada para o prosseguimento deste trabalho foi utilizar todas as variáveis-alvo sem exclusão, preservando assim três variáveis adicionais indicadoras de câncer cervical. Embora a opção de combinar todas as variáveis em uma única coluna possa inicialmente parecer vantajosa, uma vez que consolidaria as informações diagnósticas e poderia fornecer uma visão mais unificada sobre a probabilidade de ocorrência do câncer cervical, essa abordagem resulta em uma queda na qualidade das predições. Esse declínio ocorre devido à natureza distinta de detecção de cada método, que, apesar de responderem à mesma questão diagnóstica, o fazem de maneiras diferentes.

Portanto, o conjunto de dados foi replicado três vezes, totalizando quatro cópias. Em cada uma dessas cópias, foram excluídas as colunas das demais variáveis-alvo, de modo que cada conjunto mantivesse uma única variável-alvo: *Hinselmann*, *Schiller*, *Citology* e *Biopsy*. Dessa forma, todas as trinta e duas features foram preservadas em cada conjunto.

A Figura 4.2 demonstra a distribuição atual das classes 0 e 1 de cada variável.

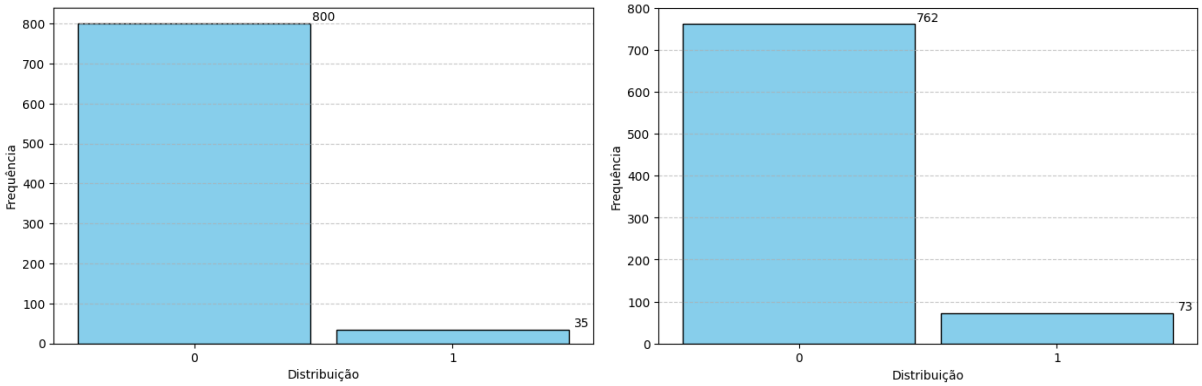

(a) Hinselmann

(b) Schiller

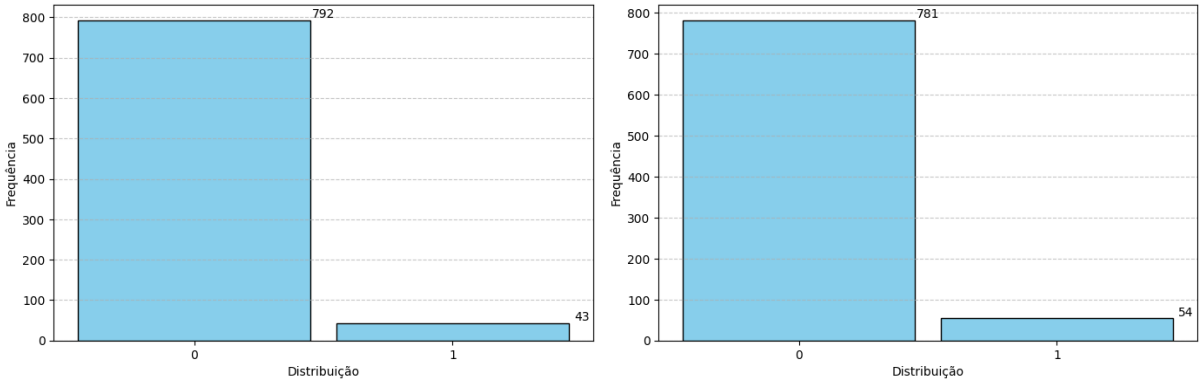

(c) Citology

(d) Biopsy

Figura 4.2 – Distribuição das 4 variáveis-alvo.

4.1.1.2 Valores Nulos

Alguns dados do conjunto de informações apresentam valores nulos, o que pode indicar que as pacientes preferiram não responder a determinadas perguntas ou não souberam informar as respostas. A Tabela 4.2 apresenta a quantidade de valores ausentes para cada variável do conjunto de dados. Para lidar com esse problema de valores ausentes e manter a consistência das análises, optou-se por preencher esses valores nulos com a média de cada respectiva variável. Essa abordagem visa minimizar o impacto de dados incompletos sem distorcer as características globais de cada feature, a fim de garantir maior eficácia nos resultados obtidos.

Tabela 4.2 – Valores nulos em cada uma das colunas.

Coluna	**Nulos**	**Coluna**	**Nulos**
Age	0	Sex partners	25
1st intercourse	7	Dx	0
Pregnancies	56	Smokes	13
Smoke yrs	13	Packs/yr	13
Hormonal Contr	103	Hormonal yrs	103
IUD	112	IUD yrs	112
STDs	100	STD num	100
Condylomatosis	100	Cervical Condylom	100
Vaginal Condylom	100	Vulvo Condylom	100
Syphilis	100	PID	100
Genital Herpes	100	molluscum	100
AIDS	100	HIV	100
Hepatitis B	100	HPV	100
STD diag num	0	1st diag time	764
Last diag time	764	Dx:Cancer	0
Dx:CIN	0	Dx:HPV	0

Fonte: Elaborado pelo autor.

Após o tratamento dos valores nulos, todas as features do conjunto de dados estão devidamente preenchidas.

4.1.1.3 Normalização

A normalização é utilizada para ajustar os valores de diferentes variáveis em uma mesma escala, sem distorcer as diferenças nos intervalos dos valores. Um dos métodos mais comuns de normalização é o $MinMaxScaler$, que transforma os dados para um intervalo entre 0 e 1, de acordo com a Equação (4.1):

$$x_n = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \tag{4.1}$$

onde x representa o valor atual da variável, enquanto $x_{\min}$ e $x_{\max}$ correspondem, respectivamente, aos valores mínimo e máximo dessa variável dentro de todo o conjunto de dados. Esse processo de normalização garante que todos os valores sejam transformados para um intervalo padronizado entre 0 e 1, facilitando a comparação entre variáveis de diferentes escalas.

4.1.1.4 Reamostragem Híbrida

Como foi retratado na Figura 4.2, a proporção de valores binários no conjunto de dados está desbalanceada, abaixo de 10% de mulheres associadas com a presença do câncer em todas as variáveis-alvo. Em problemas de classificação, especialmente aqueles com classes desbalanceadas, a classe minoritária tende a apresentar um desempenho preditivo inferior devido à falta de exemplos, o que pode influenciar negativamente o treinamento dos modelos de aprendizado de máquina. Assim, para lidar com esse desequilíbrio, existem técnicas para auxiliar no balanceamento das classes, desde simplesmente apagar valores da classe maioritária, criar novos exemplo e até a junção das duas.

O método de reamostragem utilizado para lidar com conjuntos de dados desbalanceados será o SMOTETomek, uma abordagem híbrida, visando equilibrar a disparidade apresentada. O método gera novas instâncias da classe minoritária de forma sintética e observa as criações, caso possua alguma duplicação, a linha criada será excluída, o que permite que o modelo tenha mais dados para aprender e identificar padrões dessa classe menos representada, além de evitar o overfitting.

Figura 4.3 – Distribuição das classes binárias de *Hinselmann* antes e após a reamostragem.

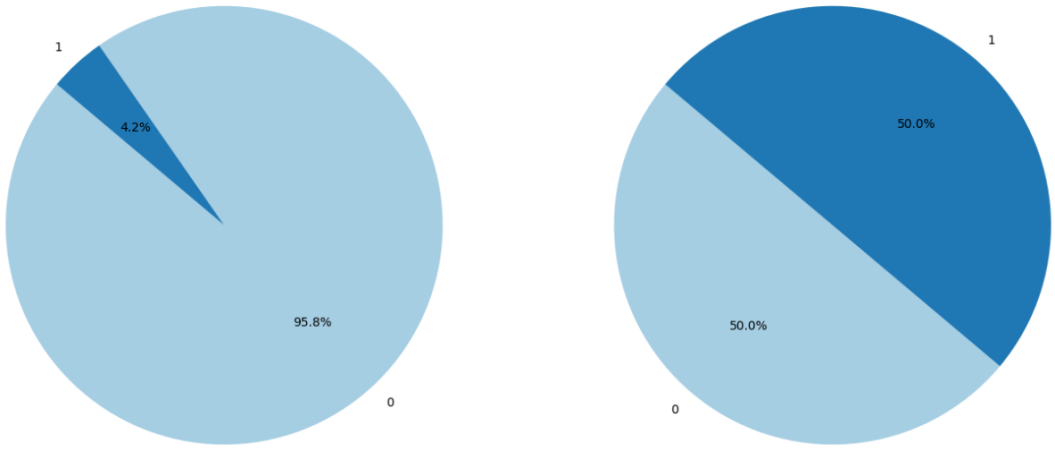

Fonte: Elaborado pelo autor.

A Figura 4.3 demonstra a aplicação do SMOTETomek na classe minoritária da variável-alvo *Hinselmann*, onde, inicialmente, apresentava 4.2% de amostras com a presença do câncer e após o uso do método de reamostragem híbrida, passou a ter 50% dos dados com e sem alterações cancerígenas. Logo, o mesmo procedimento foi reproduzido para as demais variáveis-alvo.

4.1.2 Seleção de Features

Concluída a etapa de pré-processamento, os quatro conjuntos de dados passaram a conter trinta e duas features e uma variável-alvo específica. Em casos onde o dataset possui grande número de colunas, é uma boa prática aplicar técnicas de redução de dimensionalidade, com finalidade de reduzir a complexidade do conjunto de dados, eliminando variáveis redundantes ou irrelevantes. Dessa forma, a etapa de treinamento se torna mais eficiente, uma vez que a diminuição no número de features reduz a quantidade de conexões analisadas pelos modelos, melhorando o desempenho computacional.

Dentre as técnicas disponíveis, utilizou-se a seleção por random forest, a qual realiza a comparação de cada uma das colunas com a variável-alvo. Esse processo envolve a divisão do conjunto de dados em X e y, onde X recebe todas as características e y recebe a classificação associada a essas características. O algoritmo, então, calcula a influência de cada feature em relação ao valor binário de y, encontrando aquelas com maior poder de determinar a classe. Ao final do processo, cada uma das features terá um valor numérico de importância ligada à variável-alvo, o que demonstra quais são as características mais influentes no resultado final.

As Figuras Figura 4.4, Figura 4.5, Figura 4.6 e Figura 4.7 ilustram comparativamente as cinco features mais relevantes identificadas por cada método de detecção de alterações cancerígenas analisado. A análise comparativa demonstra as variações nas seleções entre os diferentes métodos e a presença de colunas de dados exclusivas em cada abordagem.

Figura 4.4 – Top 5 features em relação ao *Hinselmann*.

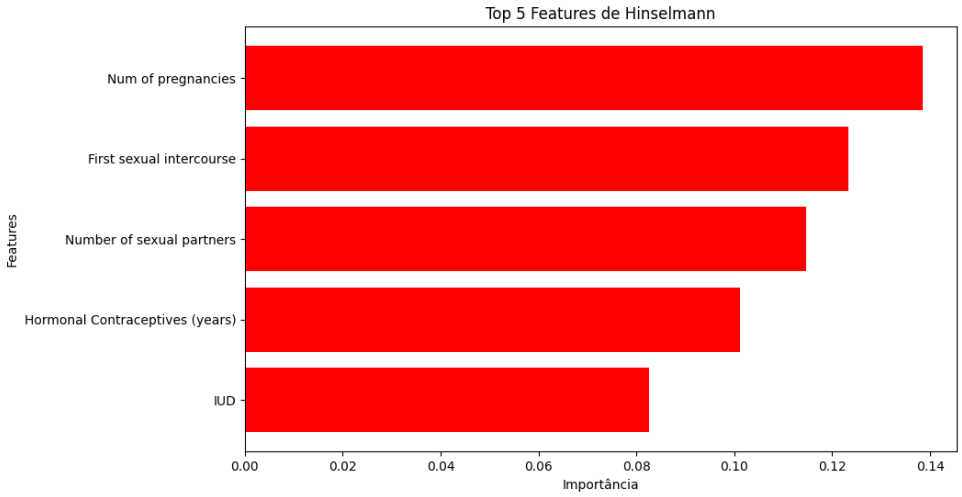

Fonte: Elaborado pelo autor.

Figura 4.5 – Top 5 features em relação ao *Schiller*.

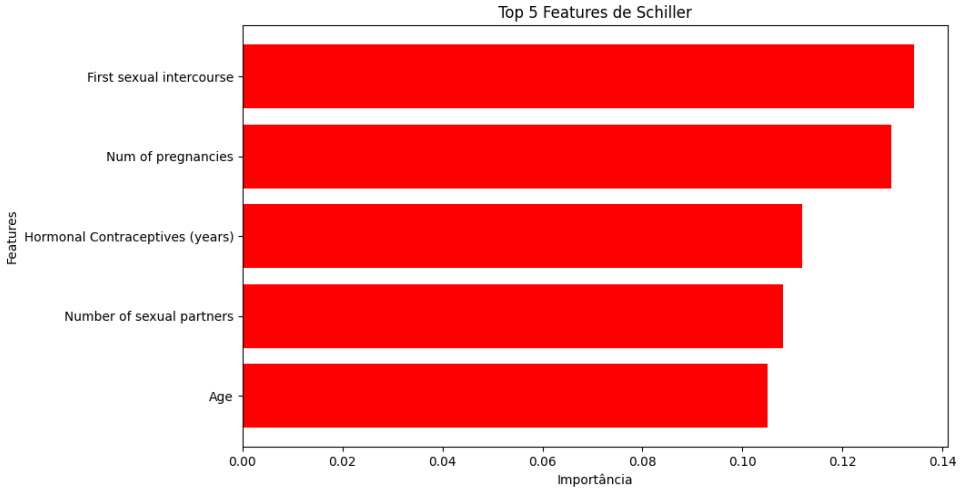

Fonte: Elaborado pelo autor.

Figura 4.6 – Top 5 features em relação ao *Citology*.

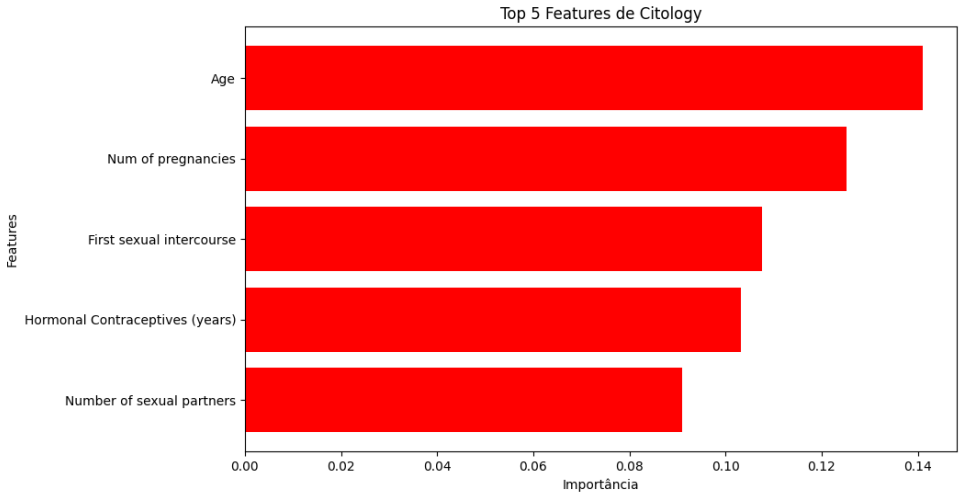

Fonte: Elaborado pelo autor.

Figura 4.7 – Top 5 features em relação ao *Biopsy*.

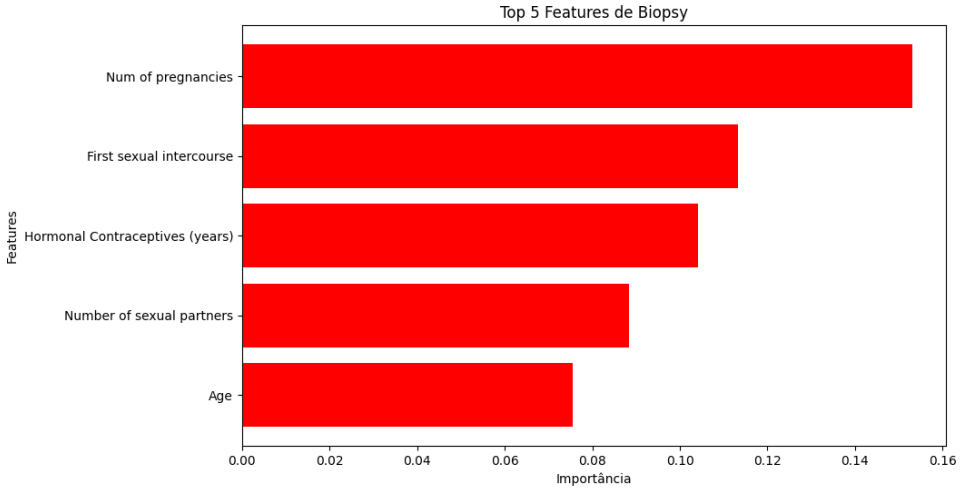

Fonte: Elaborado pelo autor.

Com isso, essas cinco features abordadas em cada teste estarão compondo um novo dataset disponível para a etapa de treinamento. A Tabela 4.3 aponta como o conjunto de dados com a variável-alvo *Hinselmann* está disposta.

O processo de seleção de features para variável-alvo *Hinselmann* identificou um conjunto conciso de variáveis fortemente associadas ao risco de alterações uterinas: Uso de DIU, Tempo de uso de Contraceptivos Hormonais, Número de Parceiros Sexuais, Idade da Primeira Relação Sexual e Número de Gravidezes. Esta seleção encontra notável semelhança na literatura médica, pois a relação entre a multiplicidade de parceiros sexuais e a idade precoce da atividade sexual é um consenso na etiologia do câncer cervical, por estarem diretamente associados à maior probabilidade de exposição e persistência ao Papilomavírus Humano, o principal fator de risco para a doença.

O número de gravidezes e o uso prolongado de contraceptivos hormonais também são amplamente discutidos como fatores que podem influenciar o ambiente hormonal e

Tabela 4.3 – Conjunto de dados atual para *Hinselmann*.

Coluna	**Tipo de Dado**
IUD	boolean
Hormonal Contraceptives (years)	int
Number of sexual partners	int
First sexual intercourse	int
Num of pregnancies	int
Hinselmann	boolean

Fonte: Elaborado pelo autor.

imunológico local, potencialmente afetando a progressão de lesões. A presença do DIU como uma variável relevante, por sua vez, é um tópico de pesquisas mais recentes, com alguns estudos sugerindo um efeito protetor, possivelmente relacionado a uma resposta imune provocada pelo dispositivo. Portanto, o modelo desenvolvido não apenas apresenta poder preditivo, mas também valida conhecimentos clínicos estabelecidos a partir dos dados, reforçando a confiabilidade de sua estrutura. Isto sugere que um sistema de apoio à decisão baseado nessas variáveis poderia ser clinicamente útil.

4.2 Treinamento

O treinamento foi realizado após as etapas de pré-processamento e seleção de features. Para iniciar, os dados são separados em X e y para as fases de treino e teste, utilizando uma proporção de 70% para treino e 30% para teste, após isso, os dados foram treinados por seis diferentes algoritmos de machine learning, conforme descritos no Capítulo 2, onde, para cada algoritmo diferente, as métricas de desempenho precision, recall, accuracy e f1_score são coletadas e organizadas em uma tabela. Posteriormente, essas métricas serão analisadas utilizando os métodos de múltipla escolha AHP e TOPSIS, permitindo uma avaliação criteriosa do desempenho de cada algoritmo.

Este mesmo processo metodológico foi replicado para cada uma das variáveis-alvo, incluindo posteriormente a análise com os métodos MCDM.

4.3 Aspectos Éticos

Este estudo foi conduzido em estrita conformidade com os princípios éticos que regem a pesquisa acadêmica. Contudo, a sua natureza específica dispensa a necessidade de submissão e aprovação prévia por um Comité de Ética em Pesquisa (CEP), pois a fonte de dados utilizada, presente na plataforma de repositório UCI, é pública e anônima, além disso, não há interação com mulheres para coleta de dados.

Portanto, por tratar-se de uma análise com dados públicos e anônimos, cujo foco é metodológico e não envolve seres humanos de forma direta, este trabalho está isento de apreciação por um CEP, assegurando, simultaneamente, o pleno respeito pelos princípios éticos da pesquisa.

5 RESULTADOS E DISCUSSÕES

Neste capítulo, são apresentados os resultados obtidos ao longo do desenvolvimento do estudo, que teve como foco a previsão de câncer do colo do útero utilizando técnicas de machine learning e métodos de Tomada de Decisão Multicritério. Todas as etapas descritas no Capítulo 4 foram aplicadas ao conjunto de dados, gerando a análise final com MCDM.

5.1 AHP

O método AHP pode ser aplicado antes do treinamento do conjunto de dados, pois não é necessário utilizar valores das métricas de desempenho. Entretanto, é preciso estar em conformidade com os critério e as alternativas abordadas na etapa de treino. Dessa forma, a organização hierárquica do método é exibido na Figura 5.1.

Figura 5.1 – Estrutura hierárquica com critérios e alternativas.

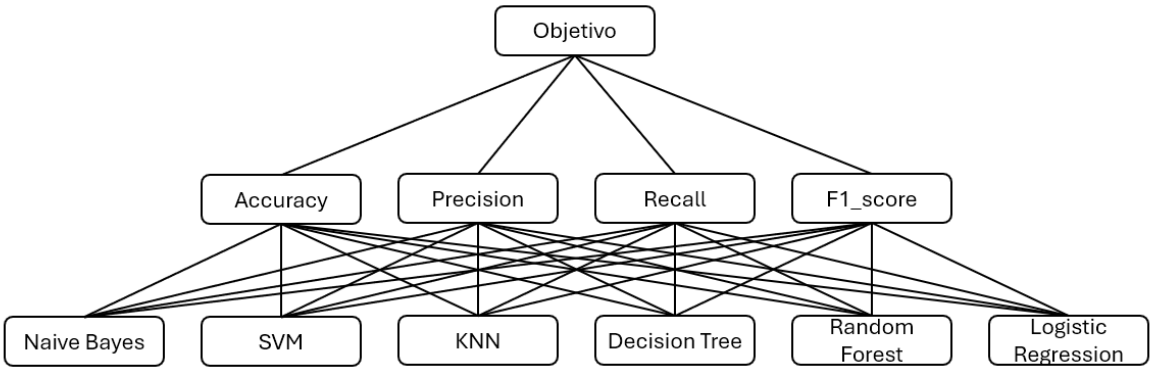

Fonte: Elaborado pelo autor.

5.1.1 Distribuição de Importâncias do AHP

O próximo passo do método AHP é a comparação par a par dos os critérios para estabelecer a distribuição de importâncias entre eles. Dessa forma, considerando o conhecimento próprio e que falsos negativos são indesejados, a distribuição inicial de importâncias pode ser vista na Tabela 5.1.

Tabela 5.1 – Distribuição de importâncias.

	Accuracy	**Precision**	**Recall**	**F1_score**
Accuracy	1.000000	0.333333	0.333333	2.000000
Precision	3.000000	1.000000	0.500000	2.000000
Recall	3.000000	2.000000	1.000000	3.000000
F1_score	0.500000	0.500000	0.333333	1.000000

Fonte: Elaborado pelo autor.

Para interpretar corretamente a tabela de distribuição das importâncias, é fundamental compreender o impacto de cada métrica na avaliação do modelo, especialmente quando o principal objetivo é minimizar falsos negativos.

A primeira métrica, accuracy, mede a proporção de predições corretas em relação ao total de amostras. Embora seja uma métrica útil para avaliar o desempenho geral do modelo, ela não diferencia adequadamente entre falsos negativos e falsos positivos. Dessa forma, em contextos onde a minimização de falsos negativos é essencial, a accuracy não deve receber um peso elevado na análise.

Em seguida, a métrica precision foca na proporção de predições positivas que são, de fato, verdadeiras. Apesar de ser um indicador relevante para garantir que as predições positivas sejam confiáveis, ela não está diretamente orientada para a redução de falsos negativos. Por esse motivo, sua importância pode ser considerada maior do que a de accuracy, mas inferior à de recall.

Por outro lado, a métrica recall mede a proporção de verdadeiros positivos corretamente identificados em relação a todas as amostras que realmente pertencem à classe positiva. Como o principal objetivo é minimizar falsos negativos, o recall se torna a métrica mais relevante, pois indica a capacidade do modelo de capturar casos positivos reais. Dessa forma, sua importância deve ser priorizada em relação às demais métricas.

Por fim, o f1_score combina precision e recall em uma média harmônica, equilibrando ambas as métricas para oferecer uma visão mais robusta do desempenho do modelo. Embora o f1_score ajude a balancear falsos positivos e falsos negativos, ele não foca exclusivamente na redução dos falsos negativos. Portanto, sua importância será semelhante à de accuracy.

5.1.2 Verificação de Consistência

A verificação de consistência foi realizada utilizando os valores de importância atribuídos aos critérios. Para garantir fontes distintas, foram aplicadas três abordagens de verificação: utilizando uma calculadora AHP online especializada em calcular a consistência, onde os critérios e suas importâncias foram replicados para efetuar o cálculo automático; com código em linguagem Python, usando a biblioteca *ahpy*; e, por fim, com cálculos na ferramenta Excel, reproduzindo todos os passos matemáticos envolvidos.

As três abordagens apresentaram um índice de consistência de 5.2%, com uma mínima variação numérica no caso da planilha Excel, possivelmente devido a arredondamentos. Assim, é favorável concluir que a distribuição de importâncias é aceitável e consistente, sendo válido usar os pesos calculados, demonstrados na Tabela 5.2 para a próxima etapa do processo, a qual consiste em adotar os pesos do AHP para a entrada do método TOPSIS.

Tabela 5.2 – Pesos dos critérios.

Critérios	**Recall**	**Precision**	**Accuracy**	**F1_score**
Peso	0.441	0.290	0.152	0.117

Fonte: Elaborado pelo autor.

5.2 TOPSIS

O método TOPSIS é aplicado para ranquear alternativas com base em sua proximidade à solução ideal. Para isso, o método requer, como entrada, os resultados numéricos obtidos para cada alternativa nas métricas definidas, assim como os pesos atribuídos a essas métricas. Esses pesos, que refletem a importância relativa de cada métrica, foram

calculados por meio do método AHP, garantindo que cada critério seja ponderado de acordo com sua relevância para o problema.

Neste estudo, o TOPSIS será aplicado quatro vezes, uma para cada variável-alvo, o que resultará em um ranqueamento específico das alternativas, permitindo uma análise detalhada do desempenho do modelo para cada uma das variáveis-alvo.

Além disso, todos os cálculos necessários para a execução do TOPSIS e obtenção dos ranqueamentos finais foram implementados em linguagem Python, seguindo todos os passos matemáticos que definem o método. Essa implementação permitiu a automatização do processo de ranqueamento e garantiu precisão nos resultados, facilitando a análise e a comparação.

5.2.1 Ranqueamento Hinselmann

Após o treinamento com os demais algoritmos do dataset com a variável-alvo Hinselmann os dados foram extraídos, conforme a Tabela 5.3.

Tabela 5.3 – Desempenho dos modelos para Hinselmann.

Modelo	**Acurácia**	**Precisão**	**Recall**	**F1 Score**
SVM	0.825000	0.785441	0.879828	0.829960
Random Forest	0.956250	0.981818	0.927039	0.953642
Logistic Regression	0.652083	0.628906	0.690987	0.658487
KNN	0.906250	0.864341	0.957082	0.908350
Naive Bayes	0.668750	0.629371	0.772532	0.693642
Decision Tree	0.952083	0.960526	0.939914	0.950108

Fonte: Elaborado pelo autor.

Prosseguindo após obtenção da tabela com os valores necessários, os cálculos do método são aplicados para determinação do ranking final de alternativas. Os resultados completos deste processo de ranqueamento encontram-se detalhados na Tabela 5.4.

Tabela 5.4 – Ranqueamento dos modelos para Hinselmann.

Modelo	**TOPSIS_R**
Decision Tree	0.940498
Random Forest	0.913133
KNN	0.833660
SVM	0.616123
Naive Bayes	0.229562
Logistic Regression	0.000000

Fonte: Elaborado pelo autor.

Os resultados do ranqueamento demonstram que a DT se posiciona como a técnica de machine learning mais adequada para a variável-alvo em questão, considerando a avaliação específica estabelecida. É fundamental observar que a seleção da melhor alternativa não se baseou exclusivamente em uma métrica de interesse, conforme evidenciado pelo algoritmo KNN, embora apresentasse a maior taxa de recall, não foi a alternativa selecionada como ótima.

5.2.2 Ranqueamento Schiller

Tabela 5.5 – Desempenho dos modelos Schiller.

Modelo	**Accuracy**	**Precision**	**Recall**	**F1_score**
SVM	0.676856	0.745283	0.626984	0.681034
Random Forest	0.930131	0.962185	0.908730	0.934694
Logistic Regression	0.539301	0.625767	0.404762	0.491566
KNN	0.790393	0.774648	0.873016	0.820896
Naive Bayes	0.548035	0.651007	0.384921	0.483791
Decision Tree	0.875546	0.873563	0.904762	0.888889

Fonte: Elaborado pelo autor.

Tabela 5.6 – Ranqueamento dos modelos para Schiller.

Modelo	**TOPSIS_R**
Random Forest	1.000000
Decision Tree	0.865213
KNN	0.719228
SVM	0.425261
Naive Bayes	0.038515
Logistic Regression	0.029783

Fonte: Elaborado pelo autor.

Para *Schiller*, o ranqueamento final indicou que a random forest é a técnica mais adequada para a variável-alvo em questão, conforme os critérios abordados.

5.2.3 Ranqueamento Citology

Tabela 5.7 – Desempenho dos modelos para Citology.

Modelo	**Accuracy**	**Precision**	**Recall**	**F1_score**
SVM	0.831933	0.777397	0.938017	0.850187
Random Forest	0.953782	0.958333	0.950413	0.954357
Logistic Regression	0.689076	0.662069	0.793388	0.721805
KNN	0.884454	0.840000	0.954545	0.893617
Naive Bayes	0.703782	0.661342	0.855372	0.745946
Decision Tree	0.911765	0.900000	0.929752	0.914634

Fonte: Elaborado pelo autor.

Tabela 5.8 – Ranqueamento dos Modelos para Citology.

Modelo	**TOPSIS_R**
Random Forest	0.979953
Decision Tree	0.832887
KNN	0.797115
SVM	0.677417
Naive Bayes	0.281232
Logistic Regression	0.001264

Fonte: Elaborado pelo autor.

Para variável-alvo *Citology*, a random forest novamente foi selecionada.

5.2.4 Ranqueamento Biopsy

Tabela 5.9 – Desempenho dos modelos para Biopsy.

Modelo	**Accuracy**	**Precision**	**Recall**	**F1_score**
SVM	0.756930	0.729927	0.833333	0.778210
Random Forest	0.938166	0.960699	0.916667	0.938166
Logistic Regression	0.541578	0.578616	0.383333	0.461153
KNN	0.848614	0.798587	0.941667	0.864245
Naive Bayes	0.594883	0.640449	0.475000	0.545455
Decision Tree	0.906183	0.929825	0.883333	0.905983

Fonte: Elaborado pelo autor.

Tabela 5.10 – Ranqueamento dos Modelos para Biopsy.

Modelo	**TOPSIS_R**
Random Forest	0.965110
Decision Tree	0.904450
KNN	0.793561
SVM	0.649528
Naive Bayes	0.162086
Logistic Regression	0.000000

Fonte: Elaborado pelo autor.

Mais uma vez, o algoritmo random forest foi selecionado.

5.3 Ranqueamento

A avaliação sistemática dos resultados obtidos pelo método TOPSIS revelou que os algoritmos random forest e decision tree apresentaram a melhor adequação ao conjunto de dados em estudo. Esta conclusão baseia-se nos critérios de julgamentos estabelecidos e pelas entradas fornecidas pelo método AHP. Embora o RF tenha geralmente superado o DT, ambos compartilham a mesma base conceitual, o que explica a proximidade deles no ranqueamento.

5.4 Comparação de Resultados

Os resultados obtidos através da aplicação dos métodos AHP e TOPSIS revelaram que o random forest e o decision tree se destacaram sobre as demais alternativas, sendo os modelos mais adequados para prever casos de câncer cervical conforme critérios adotados. Além disso, foi detectado uma boa razão de consistência, garantindo que as importâncias atribuídas aos critérios foram coerentes. Ressalta-se, também, como a adoção de métodos multicritérios são importantes para fugir da situação de eleição com apenas uma métrica. Em algumas análises, o KNN conseguiu obter a métrica recall maior que os demias algoritmos, no entanto, apesar de ser a métrica com maior importância, a técnica supervisionada não foi selecionada como a melhor, mostrando que o ranqueamento não se baseia somente nessa métrica.

O ranqueamento obtido pelo método TOPSIS demonstrou consistência ao longo das diferentes variáveis-alvo, apresentando apenas pequenas variações em sua ordenação. Enquanto o random forest e o decision tree mantiveram desempenho superior, o logistic regression, embora teoricamente adequado para problemas de classificação binária, ficou sistematicamente em última posição, revelando limitações na modelagem desse contexto específico. Esses resultados foram viabilizados por um processamento de dados rigoroso, que incluiu desde o tratamento de valores nulos e normalização até etapas críticas como a reamostragem híbrida e a seleção de features, garantindo a qualidade e as melhores características.

A equipe de Choudhury, Wesabi e Won (2018) investigou vários classificadores, como naive bayes, decision tree, logistic regression, KNN e SVM, com o destaque para o DT, o qual superou os demais e alcançou precision de 92.60% apesar de não haver seleção de features. Os autores fizeram testes com os 3 tipos de reamostragem, obtendo melhor resultado com a aplicação do SMOTETomek. A limitação encontrada ocorreu por causa do overfitting do modelo, além disso, somente a variável-alvo *Biopsy* foi mantida no dataset.

O trabalho de Singh (2018) se destaca por sua metodologia que combina SVM, random forest e GBM com técnicas avançadas como algoritmos genéticos e otimização bayesiana para seleção de features e BorderlineSMOTE para reamostragem. O GBM obteve o melhor desempenho, 77.8% de recall, superando SVM, com 55.58%, e RF, com 44.4%, mas ainda é possível melhorar. A diminuição de dimensionalidade reduziu as features para 7 e também foram descartadas as variáveis-alvo *Hinselmenn*, *Schiller* e *Citology*.

O estudo de Ijaz, Attique e Son (2020) se destaca por manter todas as variáveis-alvo originais, aplicando uma abordagem robusta: a combinação de DBSCAN e iForest para remoção de outliers, SMOTETomek para reamostragem e teste qui-quadrado para selecionar as 10 features mais relevantes. Entre os algoritmos testados, o random forest obteve os melhores resultados gerais, com destaque a um recall máximo de 98%, reforçando sua eficácia.

O estudo de Ali et al. (2024) analisou dois datasets sobre câncer cervical, um com 20 features comportamentais e outro com 36 dados clínicos (o mesmo desta pesquisa), porém apresentou limitações metodológicas significativas: não tratou o desbalanceamento de classes, manteve todas as features comportamentais, reduziu somente o dataset clínico para 15 features com método SMOTE, manteve a variável-alvo *Biopsy* e descartou as outras e baseou sua avaliação principal apenas na accuracy, apesar de ter calculado outras métricas mais relevantes para o contexto.

O estudo de Tanimu et al. (2022), utilizando o mesmo dataset, aplicou o SMOTETomek para reamostragem e comparou dois métodos de seleção de features (LASSO e RFE), escolhendo as 10 variáveis mais relevantas para treinar um modelo com DT. Os

resultados demonstraram que a redução de dimensionalidade melhorou significativamente o desempenho, com o RFE alcançando a maior accuracy de 97.42%, superando tanto o LASSO quanto o modelo sem seleção de features, comprovando a importância da seleção adequada de características do conjunto para otimizar os resultados de algoritmos de machine learning.

O estudo de Fatlawi (2017), ao trabalhar com as quatro variáveis-alvo originais do dataset, seguiu uma abordagem questionável ao agregá-las em uma única variável categórica ordinal, chamada *Cancer*, variando de 0 a 4. Essa simplificação, embora reduza a complexidade do problema, pode comprometer a riqueza diagnóstica dos dados originais. Para redução de dimensionalidade, os autores aplicaram seleção de features e utilizaram decision tree e uma de suas variantes para treinamento, porém os resultados apresentaram desempenho insatisfatório, com todas as métricas ficando abaixo de 50%. Esse baixo desempenho sugere que a estratégia de agregação das variáveis-alvo limitou significativamente a capacidade preditiva do modelo.

O estudo de Deng, Luo e Wang (2018) adotou uma abordagem metodológica distinta ao analisar separadamente as quatro variáveis-alvo, realizando quatro treinamentos independentes com SVM, random forest e XGBoost, combinados ao Borderline-SMOTE para reamostragem. Embora os resultados tenham sido expressivos, com o RF alcançando 97% de accuracy e desempenho notável em precision e recall, a ausência de seleção de features, levanta questões sobre a generalização do modelo, limitando-se à exclusão de algumas linhas com valores nulos.

O estudo de Akdag, Menekse e Sahin (2024) apresenta contribuição relevante, onde é proposta uma metodologia de tomada de decisão multicritério difusa integrada ao machine learning para avaliar os níveis de risco de câncer cervical em pacientes. A metodologia proposta é estabelecida em três etapas: primeiro, uma técnica de seleção de features é aplicada; em sequência, ocorre a atribuição de pesos aos critérios selecionados; e, por fim, os níveis de risco de câncer cervical são priorizados usando a técnica TOPSIS.

O estudo de Mustapha et al. (2022) demonstra a versatilidade do MCDM ao aplicá-lo na predição de câncer de mama, utilizando o método PROMETHEE para avaliar e classificar algoritmos de machine learning segundo dez critérios de decisão específicos. A metodologia adotada pelos autores permitiu uma comparação sistemática entre diferentes técnicas, resultando na seleção do SVM como o algoritmo mais adequado para o contexto investigado. Essa aplicação reforça o potencial dos métodos multicritério para auxiliar na tomada de decisão médica.

O estudo de Ali e Broumi (2024) propôs um sistema integrado combinando machine learning e tomada de decisão multicritério para análise do câncer de tireoide, avaliando três algoritmos (logistic regression, SVM e random forest) com desempenhos distintos em diferentes métricas. Para resolver essa disparidade, os autores aplicaram o método TOPSIS, que considerou, de forma equilibrada, múltiplos critérios de avaliação, resultando na seleção do SVM como o modelo mais adequado para a tarefa. Contudo, ao se usar métodos que pedem valores de entrada, uma boa prática é o uso adicional do AHP, pois ele fornece maior fundamento aos pesos calculados, diminuindo a dependência do conhecimento prévio dos critérios ao atribuir pesos.

A integração de métodos multicritérios com o dataset de câncer do colo do útero demonstrou ser uma abordagem eficaz, embora ainda pouco explorada na literatura para seleção de algoritmos de machine learning. Nossa pesquisa aplicou com sucesso técnicas MCDM para ranquear alternativas com base nos resultados dos treinamentos, superando a limitação das abordagens tradicionais que se baseiam em métricas isoladas. Os resultados obtidos revelaram uma melhoria significativa em comparação com outros estudos, graças

a um processo criterioso que incluiu: tratamento do dataset e variáveis-alvo; seleção de features através do SMOTETomek; e avaliação multicritério do desempenho. Essa metodologia sistemática permitiu alcançar métricas superiores, validando o potencial da abordagem proposta para aplicações em diagnóstico médico.

5.5 Pontos de Atenção

A disparidade na distribuição das classes do conjunto de dados, onde a classe positiva (indicativa de câncer) representa aproximadamente apenas 5% das 836 instâncias, impõe desafios substanciais à modelagem, pois este desbalanceamento severo eleva significativamente o risco de overfitting, mesmo com técnicas de balanceamento como o SMOTETomek. Um modelo pode facilmente memorizar os poucos padrões da classe minoritária ou aprender a ignorá-la, tornando-se um classificador trivial que sempre prevê a classe majoritária e ainda assim atinge uma alta acurácia geral, porém falha completamente em seu propósito.

Outro aspecto crucial é discutir os possíveis vieses inerentes ao dataset. Os dados foram coletados em um único hospital em Caracas o que introduz um viés geográfico, socioeconômico e potencialmente cultural. A população representada pode não ser generalizável para outras regiões ou grupos demográficos. O próprio mecanismo de coleta em um ambiente hospitalar introduz um viés de seleção, já as pacientes presentes no dataset são, por definição, aquelas que buscaram atendimento médico, possivelmente sub-representando indivíduos assintomáticos ou com acesso limitado à saúde. Portanto, as conclusões deste estudo devem ser interpretadas dentro deste contexto específico, e a validação em populações mais amplas e diversificadas constitui um passo futuro essencial.

6 CONCLUSÃO

O câncer cervical permanece um desafio crítico para a saúde pública, especialmente na região Norte do Brasil, onde barreiras socioeconômicas e geográficas dificultam o diagnóstico precoce. Este estudo explorou com sucesso a integração entre técnicas de machine learning e métodos multicritérios, propondo uma abordagem inovadora para selecionar o modelo mais robusto na predição da doença para critérios específicos. Com isso, o random forest emergiu como o algoritmo mais adequado dentre os testados, seguido pelo decision tree.

A metodologia desenvolvida integrou de forma estratégica os métodos AHP e TOPSIS para uma melhor avaliação dos algoritmos de machine learning. O AHP foi empregado para estabelecer os pesos relativos dos critérios de desempenho, considerando não apenas a accuracy, mas também outras métricas, servindo como base de entrada para o TOPSIS, que realizou o ranqueamento final dos modelos, revelando o random forest como o melhor. Além disso, o rigor no pré-processamento dos dados, incluindo técnicas avançadas de reamostragem e seleção features, foi fundamental para garantir a qualidade dos dados de entrada, permitindo que os modelos expressassem todo seu potencial preditivo.

O estudo enfrentou desafios significativos relacionados ao dataset, exigindo decisões metodológicas cuidadosas para garantir a qualidade da análise. Três questões centrais foram desafiadoras: múltiplas variáveis-alvo; significativo desequilíbrio entre classes; e muitas features envolvidas nos conjuntos.

A estratégia de separar as variáveis-alvo em conjuntos distintos foi cuidadosamente fundamentada na análise crítica das abordagens existentes para o mesmo dataset. A revisão da literatura revelou quatro principais metodologias: a exclusão seletiva de três variáveis, mantendo apenas os resultados de biópsia; a agregação das variáveis em uma escala ordinal única (0-4); a junção das quatro, mas mantendo valor binário; e a separação das variáveis em datasets. Com isso, optou-se pela abordagem de separar e preservar integralmente as informações diagnósticas de cada exame, evitando tanto a perda de dados quanto a simplificação do problema.

Outro aspecto crucial do estudo foi a aplicação do SMOTETomek, técnica híbrida que combina a geração sintética de amostras com a limpeza de ruídos. Essa abordagem mostrou-se eficaz para equilibrar as classes, criando novas instâncias da classe minoritária com base nas existentes. No entanto, uma limitação relevante do método é sua tendência de amplificar ruídos presentes nos dados originais, visto que as amostras sintéticas herdam as características dos dados reais. Apesar disso, essa limitação foi mitigada pela etapa anterior de tratamento de valores faltantes e a normalização das variáveis.

Além disso, considerando a multidimensionalidade dos dados, a seleção de features foi necessária para eleger aquelas que mais impactavam na predição da variável-alvo. Diante disso, optou-se pelo método embedded com o algoritmo random forest classifier, que avalia a importância das variáveis durante o próprio processo de treinamento, retornando as n variáveis mais importantes. Assim, para cada variável-alvo 5 features com maior relevância foram escolhidas.

Portanto, com a escolha deliberada de focar em algoritmos clássicos de ML, o que, por consequência, não inclui uma comparação direta com paradigmas e técnicas mais modernas, como perspectiva, sugere-se a ampliação deste modelo de estudo a outros contextos e a aplicação de frameworks avançados de gradient boosting, como XGBoost, LightGBM e CatBoost, bem como arquiteturas de redes neurais. Além disso, é possível

abordar a utilização de outros conjuntos de dados clínicos, a revisão dos critérios e importâncias adicionadas ao método AHP, a exploração de técnicas de otimização de hiperparâmetros mais robustas, como otimização bayesiana, entre outros. Com isso, a aplicação dessa metodologia em outros tipos de câncer ou contextos médicos pode contribuir significativamente para aprimorar o diagnóstico precoce e reduzir a mortalidade associada a doenças críticas.

REFERÊNCIAS

AKDAG, H. C.; MENEKSE, A.; SAHIN, F. Cervical cancer risk assessment using machine learning integrated fuzzy mcdm methodology. p. 4573–4592, jan 2024. Citado 3 vezes nas páginas 37, 38 e 53.

AKINSOLA, T.; KUYORO, O.; AWODELE, O.; KASALI, A. Performance Evaluation of Supervised Machine Learning Algorithms Using Multi-Criteria Decision Making Techniques. In: **International Conference on Education and Development (ITED)**. [S.l.: s.n.], 2019. Citado na página 14.

ALGHAMDI, M.; AL-MALLAH, M.; KETEYIAN, S.; BRAWNER, C.; EHRMAN, J.; SAKR, S. Predicting diabetes mellitus using smote and ensemble machine learning approach: The henry ford exercise testing (fit) project. **PloS one**, Public Library of Science San Francisco, CA USA, v. 12, n. 7, p. e0179805, 2017. Citado 2 vezes nas páginas 33 e 34.

ALI, A.; SHAUKAT, S.; TAYYAB, M.; KHAN, M. A.; KHAN, J. S.; AHMAD, J. et al. Network intrusion detection leveraging machine learning and feature selection. In: IEEE. **2020 IEEE 17th International Conference on Smart Communities: Improving Quality of Life Using ICT, IoT and AI (HONET)**. [S.l.], 2020. p. 49–53. Citado na página 34.

ALI, A. M.; BROUMI, S. Machine learning with multi-criteria decision making model for thyroid disease prediction and analysis. **Multicriteria Algorithms with Applications**, v. 2, p. 80–88, Jan. 2024. Disponível em: <https://sciencesforce.com/index.php/mawa/article/view/73>. Citado 3 vezes nas páginas 37, 38 e 53.

ALI, M.; HOSSAIN, M.; KONA, M.; NOWRIN, K.; ISLAM, M. An ensemble classification approach for cervical cancer prediction using behavioral risk factors. **Healthcare Analytics**, v. 5, p. 100324, 03 2024. Citado 3 vezes nas páginas 36, 38 e 52.

BARRETO, R. G. e. a. Utilizando Redes Neurais Artificiais para o Diagnóstico de Câncer Cervical. **Revista Saúde e Ciência online**, v. 7, n. 2, p. 502, ago 2018. Citado na página 14.

BINDER, M. et al. On the Antiquity of Cancer: Evidence for Metastatic Carcinoma in a Young Man from Ancient Nubia (c. 1200BC). **PLoS ONE**, v. 9, n. 3, p. e90924, mar 2014. Citado na página 17.

BREIMAN, L.; FRIEDMAN, J. H.; OLSHEN, R. A.; STONE, C. J. **Classification and Regression Trees**. Belmont, CA: Wadsworth, 1984. Citado na página 35.

BUANI, D. P.; SURYANI, I. Implementation of Machine Learning Algorithms for Early Detection of Cervical Cancer Based on Behavioral Determinants. **Jurnal Riset Informatika**, v. 5, n. 1, dec 2022. Citado na página 29.

BUZAID, A. Carlos and MALUF, F. Cotait. **Instituto Vencer o Câncer: Câncer de colo do útero: O que é?** 2024. Acesso em: 10 junho 2025. Disponível em: <https://vencerocancer.org.br/tipos-de-cancer/cancer-de-colo-do-utero-o-que-e/>. Citado na página 14.

CHANDRASHEKAR, G.; SAHIN, F. A survey on feature selection methods. **Computers & electrical engineering**, Elsevier, v. 40, n. 1, p. 16–28, 2014. Citado na página 34.

CHEN, X.-w.; JEONG, J. C. Enhanced recursive feature elimination. In: IEEE. **Sixth international conference on machine learning and applications (ICMLA 2007)**. [S.l.], 2007. p. 429–435. Citado na página 35.

CHOUDHURY, A.; WESABI, Y.; WON, D. Classification of cervical cancer dataset. **arXiv preprint arXiv:1812.10383**, 2018. Citado 3 vezes nas páginas 36, 38 e 52.

COLAK, C.; KARAASLAN, E.; ARSLAN, A.; ERDIL, N. Handling imbalanced class problem for the prediction of atrial fibrillation in obese patient. **Biomedical Research-India**, v. 28, n. 7, 2017. Citado na página 34.

DEBROY, S. **Cancer Prediction from Genomic Analysis with Machine Learning**. 2023. Acesso em: 29 maio 2024. Disponível em: <https://medium.com/@shuv.sdr/cancer-prediction-from-genomic-analysis-with-machine-learning-c957b579f05>. Citado 2 vezes nas páginas 14 e 22.

DENG, X.; LUO, Y.; WANG, C. Analysis of risk factors for cervical cancer based on machine learning methods. In: IEEE. **2018 5th IEEE international conference on cloud computing and intelligence systems (CCIS)**. [S.l.], 2018. p. 631–635. Citado 3 vezes nas páginas 37, 38 e 53.

DUNNE, E. F.; MARKOWITZ, L. E. Human papillomavirus vaccination and prevention of cervical cancer in the united states. **New England Journal of Medicine**, 2006. Citado na página 22.

FATLAWI, H. K. Enhanced classification model for cervical cancer dataset based on cost sensitive classifier. **International Journal of Computer Techniques**, v. 4, n. 4, p. 115–20, 2017. Citado 3 vezes nas páginas 37, 38 e 53.

FERLAY, J. e. a. Global cancer statistics 2020: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. **CA: A Cancer Journal for Clinicians**, 2021. Citado na página 21.

FERNANDES, K.; CARDOSO, J.; FERNANDES, J. **Cervical Cancer (Risk Factors)**. 2017. UCI Machine Learning Repository. DOI: https://doi.org/10.24432/C5Z310. Citado na página 39.

GALMARINI, C. M. Lessons from Hippocrates: Time to Change the Cancer Paradigm. **International Journal of Chronic Diseases**, v. 2020, p. 4715426, jun 2020. Citado na página 17.

GAYATRI, N.; NICKOLAS, S.; REDDY, A. V. Proceedings of the world congress on engineering and computer science 2010 vol i. In: **WCECS 2010, October 20-22, 2010, San Francisco, USA**. [S.l.: s.n.], 2010. ISSN 2078-0958. Citado na página 35.

GHOSH, P.; AZAM, S.; JONKMAN, M.; KARIM, A.; SHAMRAT, F. J. M.; IGNATIOUS, E.; SHULTANA, S.; BEERAVOLU, A. R.; BOER, F. D. Efficient prediction of cardiovascular disease using machine learning algorithms with relief and lasso feature selection techniques. **IEEE Access**, IEEE, v. 9, p. 19304–19326, 2021. Citado na página 35.

GOEL, G.; MAGUIRE, L.; LI, Y.; MCLOONE, S. Evaluation of sampling methods for learning from imbalanced data. In: SPRINGER. **Intelligent Computing Theories: 9th International Conference, ICIC 2013, Nanning, China, July 28-31, 2013. Proceedings 9**. [S.l.], 2013. p. 392–401. Citado na página 34.

GOGONI, R. **IA do Google conseguiu o impensável: aprendeu a jogar Go**. 2016. Meio Bit. Acesso em: 03 out. 2024. Disponível em: <https://meiobit.com/336028/google-inteligencia-artificial-alphago-heuristica-supera-jogador-profissional-go/>. Citado na página 23.

HURWITZ, J.; KIRSCH, D. **Machine Learning for Dummies**. [S.l.]: [S.l.], 2000. Citado na página 23.

IJAZ, M. F.; ATTIQUE, M.; SON, Y. Data-driven cervical cancer prediction model with outlier detection and over-sampling methods. **Sensors**, MDPI, v. 20, n. 10, p. 2809, 2020. Citado 3 vezes nas páginas 36, 38 e 52.

INCA. **Diretrizes brasileiras para o rastreamento do câncer do colo do útero**. 2022. 12 de junho de 2025. Disponível em: <https://www.inca.gov.br/publicacoes/livros/diretrizes-brasileiras-para-o-rastreamento-do-cancer-do-colo-do-utero>. Citado na página 22.

INCA. **Mortalidade**. 2022. Acesso em: 20 maio 2024. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/gestor-e-profissional-de-saude/controle-do-cancer-do-colo-do-utero/dados-e-numeros/mortalidade>. Citado na página 14.

Instituto Nacional de Câncer. **Estimativa dos casos para 2023**. 2022. Acesso em: 08 janeiro 2025. Disponível em: <https://www.inca.gov.br/sites/ufu.sti.inca.local/files//media/document//estimativa-2023.pdf>. Citado 3 vezes nas páginas 18, 19 e 20.

Instituto Vencer o Câncer. **O que é o Câncer?** 2023. Acesso em: 08 janeiro 2025. Disponível em: <https://vencerocancer.org.br/o-que-e-cancer/>. Citado na página 17.

MAIA, B. **Tipos de Aprendizado de Máquina**. 2022. DEV. Acesso em: 03 out. 2024. Disponível em: <https://dev.to/beatrizmaiads/tipos-de-aprendizado-de-maquina-3-5d66>. Citado na página 24.

MALTA, L. H. A.; KUROIVA, M. A. R. L. **Aprendizado de Máquina e Processamento de Linguagem Natural aplicados à identificação de discurso de ódio**. 2019. Citado na página 24.

MORE, A. Survey of resampling techniques for improving classification performance in unbalanced datasets. **arXiv preprint arXiv:1608.06048**, 2016. Citado na página 34.

MUDAWI, N. A.; ALAZEB, A. A Model for Predicting Cervical Cancer Using Machine Learning Algorithms. **Sensors (Basel)**, v. 22, n. 11, p. 4132, may 2022. Citado na página 15.

MUSTAPHA, M. T.; OZSAHIN, D. U.; OZSAHIN, I.; UZUN, B. Breast cancer screening based on supervised learning and multi-criteria decision-making. **Diagnostics**, v. 12, n. 6, p. 1326, May 2022. Citado 3 vezes nas páginas 37, 38 e 53.

National Cancer Institute. **Cervical Cancer Treatment (PDQ) Patient Version**. 2021. Acesso em: 21 maio 2024. Disponível em: <https://www.cancer.gov/types/cervical/patient/cervical-treatment-pdq#section/_13>. Citado 2 vezes nas páginas 14 e 22.

NITHYA, B.; ILANGO, V. Evaluation of machine learning based optimized feature selection approaches and classification methods for cervical cancer prediction. **SN Applied Sciences**, Springer, v. 1, p. 1–16, 2019. Citado na página 34.

OPAS. **OPAS: Câncer do colo do útero**. 2023. 12 de junho de 2025. Disponível em: <https://www.paho.org/pt/topicos/cancer-do-colo-do-utero>. Citado na página 22.

PACHECO, A. **Computação Inteligente: TOPSIS - Um algoritmo de tomada de decisão**. 2016. 20 de junho de 2025. Disponível em: <https://computacaointeligente.com.br/algoritmos/TOPSIS-tomada-de-decisao/#:~:text=O%20TOPSIS%20%C3%A9%20muito%20utilizado,assuntos%20para%20um%20pr%C3%B3ximo%20post.> Citado na página 31.

PEDAMKAR, P. **Decision Tree Algorithm**. 2023. EDUCBA. Acesso em: 03 out. 2024. Disponível em: <https://www.educba.com/decision-tree-algorithm/>. Citado na página 26.

PENG, Y.; WU, Z.; JIANG, J. A novel feature selection approach for biomedical data classification. **Journal of biomedical informatics**, Elsevier, v. 43, n. 1, p. 15–23, 2010. Citado na página 35.

PRATI, R. C.; BATISTA, G. E.; MONARD, M. C. Data mining with imbalanced class distributions: concepts and methods. In: **IICAI**. [S.l.: s.n.], 2009. p. 359–376. Citado na página 33.

RASTGOO, M.; LEMAITRE, G.; MASSICH, J.; MOREL, O.; MARZANI, F.; GARCIA, R.; MERIAUDEAU, F. Tackling the problem of data imbalancing for melanoma classification. In: **Bioimaging**. [S.l.: s.n.], 2016. Citado na página 33.

RODRIGUEZ-GALIANO, V. F.; LUQUE-ESPINAR, J. A.; CHICA-OLMO, M.; MENDES, M. P. Feature selection approaches for predictive modelling of groundwater nitrate pollution: An evaluation of filters, embedded and wrapper methods. **Science of the total environment**, Elsevier, v. 624, p. 661–672, 2018. Citado na página 35.

SANCHEZ-MARONO, N.; ALONSO-BETANZOS, A.; TOMBILLA-SANROMAN, M. Filter methods for feature selection–a comparative study. In: SPRINGER. **International Conference on Intelligent Data Engineering and Automated Learning**. [S.l.], 2007. p. 178–187. Citado na página 34.

SANTOS, M.; GARCIA, B.; SOFISTE, V.; SILVA, F. Aplicação do método ahp na renovação do parque tecnológico de um hospital do rio de janeiro. 10 2017. Citado na página 29.

SANTOS, V. S. **Útero: Brasil Escola**. 2024. 11 de junho de 2025. Disponível em: <https://brasilescola.uol.com.br/biologia/utero.htm>. Citado na página 21.

SINGH, H. D. **Diagnosis of Cervical Cancer using Hybrid Machine Learning Models**. Tese (Doutorado) — Dublin, National College of Ireland, 2018. Citado 3 vezes nas páginas 36, 38 e 52.

SOBAR, R. M.; ADI, W. Behavior Determinant based Cervical Cancer Early Detection with Machine Learning Algorithm. **Advanced Science Letters**, v. 22, p. 3120–3123, 2016. Citado 2 vezes nas páginas 27 e 40.

SOMASUNDARAM, A.; REDDY, U. S. Data imbalance: effects and solutions for classification of large and highly imbalanced data. In: **international conference on research in engineering, computers and technology (ICRECT 2016)**. [S.l.: s.n.], 2016. p. 1–16. Citado na página 33.

TANIMU, J. J.; HAMADA, M.; HASSAN, M.; KAKUDI, H.; ABIODUN, J. O. A machine learning method for classification of cervical cancer. **Electronics**, MDPI, v. 11, n. 3, p. 463, 2022. Citado 3 vezes nas páginas 36, 38 e 52.

TECH, D. **O que é e como funciona o algoritmo KNN?** 2019. Didática Tech: Inteligência Artificial Data Science. Acesso em: 03 out. 2024. Disponível em: <https://didatica.tech/o-que-e-e-como-funciona-o-algoritmo-knn/>. Citado na página 25.

WHO. **Global Strategy to Accelerate the Elimination of Cervical Cancer as a Public Health Problem: World Health Organization**. 2020. <https://www.who.int/publications/i/item/9789240014107>. Acessado em: 2 de outubro de 2024. Citado na página 22.

WILLIAM, W.; WARE, A.; BASAZA-EJIRI, A. H.; OBUNGOLOCH, J. A review of image analysis and machine learning techniques for automated cervical cancer screening from pap-smear images. **Computer methods and programs in biomedicine**, Elsevier, v. 164, p. 15–22, 2018. Citado na página 36.

World Health Organization. **Cervical cancer**. 2019. Acesso em: 20 maio 2024. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/cervical-cancer>. Citado na página 14.

Xinying Shu. **Embedded Feature Selection Method Based on Neural Networks—Research on Simulation Application of European Football Data**. 2022. Acesso em: 22 março 2025. Disponível em: <https://ieeexplore.ieee.org/abstract/document/10660127>. Citado na página 36.

YAMADA, M.; JITKRITTUM, W.; SIGAL, L.; XING, E. P.; SUGIYAMA, M. High-dimensional feature selection by feature-wise kernelized lasso. **Neural computation**, MIT Press, v. 26, n. 1, p. 185–207, 2014. Citado na página 35.